

暨南大学硕士学位论文

题名：数据与模型双重异构下联邦学习算法研究

Title: Research on Federated Learning Algorithms under Dual
Heterogeneity of Data and Model

作者姓名：梁浩程

指导教师姓名及学位、职称：梁倬騫 博士 高级实验师

学科、专业名称：工学 计算机技术

学位类型：专业学位

论文提交时间：2026 年 6 月

论文答辩时间：2026 年 5 月

答辩委员会主席：谢晓华

论文评阅人：盲审

学位授予单位和日期：暨南大学 2026 年 6 月

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得 暨南大学 或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

学位论文作者签名：

签字日期： 年 月 日

学位论文版权使用授权书

本学位论文作者完全了解 暨南大学 有关保留、使用学位论文的规定，有权保留并向国家有关部门或机构送交论文的复印件和磁盘，允许论文被查阅和借阅。本人授权 暨南大学 可以将学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

(保密的学位论文在解密后适用本授权书)

学位论文作者签名：

导师签名：

签字日期： 年 月 日

签字日期： 年 月 日

学位论文作者毕业后去向：

工作单位：

电话：

通讯地址：

邮编：

摘 要

联邦学习作为一种隐私保护的分布式机器学习方法，在确保不上传本地原始数据的前提下，通过分布式节点协同训练全局模型。在医疗诊断、金融风控等数据敏感领域展现出广阔应用前景。然而，实际部署中客户端普遍存在双重异构性挑战：数据异构导致客户端本地数据分布存在显著差异，使本地模型更新偏离全局最优；模型异构则受限于客户端设备硬件配置的显著差异以及模型知识产权的保护需求，各参与方难以采用统一的模型架构。数据与模型的双重异构性已成为制约联邦学习性能与实用性的核心瓶颈。此外，频繁的模型交换在移动边缘计算等资源受限场景中会带来显著的通信开销，制约算法的可扩展性与实用性。因此，如何在双重异构环境下兼顾模型性能、隐私保护与通信效率，已成为当前联邦学习需要解决的关键问题。

针对上述问题，本文提出了两种新的联邦学习方法，分别是基于类内聚合与双重自适应调整的异构联邦学习算法 FedIADA 和基于原型放缩及衰减聚合的异构联邦学习算法 FedPSS：

- **FedIADA 算法。**FedIADA 在服务端提出了类内聚合机制，根据各客户端各类别样本数量及分类表现构建全局分类头，增强了类别间的区分能力。在客户端侧，构建了自适应聚合模块，通过可学习权重矩阵动态结合全局与本地分类头，在保留个性化信息的同时吸收全局知识。同时引入了自适应 logits 调整策略，根据本地数据分布对输出进行修正，提高模型对数量较少的类的关注度，从而提升模型在异构场景下的整体性能。
- **FedPSS 算法。**FedPSS 采用原型放缩策略，客户端根据本地样本数量对原型进行放大后上传，服务器聚合后经尺度缩小再下发，避免了样本数量信息的直接传输。同时由于传输的是原型而非完整模型参数，通信开销显著降低，适合带宽受限的应用环境。在服务端聚合阶段提出了步长衰减聚合机制，在服务端动态调整客户端权重，在训练初期均衡探索、后期抑制不稳定更新，提升聚合稳定性并缓解全局原型的漂移。在客户端侧引入双层对比学习策略用于本地训练，在学习全局原型知识的同时提升样本表征质量。

本文在 Fashion-MNIST、CIFAR-10 和 CIFAR-100 三个公开数据集上开展了大量实验，涵盖不同客户端规模、多种模型异构程度及数据异构强度。实验结果表明，FedIADA

与 9 种联邦学习算法相比, 在 HtFE2、HtFE4 和 HtFE5 三种模型异构配置下均取得最优分类性能, 较基线方法提升显著; FedPSS 与 8 种联邦学习算法相比, 在保持高准确率的同时, 通信开销较低, 且在整体性能与资源消耗之间取得了较好的平衡, 综合而言, 本文提出的两种算法为数据与模型双重异构场景下的联邦学习提供了高效的解决方案。

关键词: 异构联邦学习; 个性化联邦学习; 数据异构; 模型异构

Abstract

Federated learning, as a privacy-preserving distributed machine learning approach, enables collaborative training of a global model through distributed nodes without uploading raw local data. It demonstrates broad application prospects in data-sensitive domains such as medical diagnosis and financial risk control. However, in practical deployments, clients generally face dual heterogeneity challenges: data heterogeneity leads to significant differences in local data distributions across clients, causing local model updates to deviate from the global optimum; model heterogeneity arises from substantial variations in client hardware configurations and the need to protect model intellectual property, making it difficult for participating parties to adopt a unified model architecture. The dual heterogeneity of data and models has become a core bottleneck restricting the performance and practicality of federated learning. Furthermore, frequent model exchanges in resource-constrained scenarios such as mobile edge computing introduce significant communication overhead, limiting algorithm scalability and practicality. Therefore, how to balance model performance, privacy protection, and communication efficiency under dual heterogeneity has become a critical challenge that federated learning needs to address.

To address the above issues, this thesis proposes two novel federated learning methods: FedIADA, a heterogeneous federated learning algorithm based on intra-class aggregation and dual adaptive adjustment, and FedPSS, a heterogeneous federated learning algorithm based on prototype scaling and decay aggregation.

- **FedIADA algorithm.** FedIADA proposes a within-class aggregation mechanism on the server side, which constructs a global classification head based on the number of samples per class and the classification performance of each client, thereby enhancing the discriminative ability among classes. On the client side, an adaptive aggregation module is designed to dynamically combine the global and local classification heads through learnable weight matrices, preserving personalized information while absorbing global knowledge. Additionally, an adaptive logits adjustment strategy is introduced to calibrate the outputs according to the local data distribution, increasing the model's attention to classes with fewer samples, thus improving the overall performance of the model in

heterogeneous scenarios.

- **FedPSS algorithm.** FedPSS adopts a prototype scaling strategy, where clients scale up their prototypes based on the number of local samples before uploading them to the server. After the server aggregates the scaled prototypes, it scales them down before distributing them back to clients, thereby avoiding the direct transmission of sample quantity information. Additionally, since prototypes are transmitted rather than full model parameters, communication overhead is significantly reduced, making this approach suitable for bandwidth-constrained environments. In the server aggregation phase, a stepwise decay aggregation mechanism is proposed to dynamically adjust client weights on the server side. This mechanism balances exploration in the early stages of training and suppresses unstable updates in later stages, thereby improving aggregation stability and mitigating global prototype drift. On the client side, a dual-level contrastive learning strategy is introduced for local training, enabling clients to learn global prototype knowledge while improving the quality of sample representations.

Extensive experiments are conducted on three public datasets, namely Fashion-MNIST, CIFAR-10, and CIFAR-100, covering different client scales, various levels of model heterogeneity, and data heterogeneity intensities. Experimental results demonstrate that, compared with nine federated learning algorithms, FedIADA achieves optimal classification performance under three model heterogeneity configurations, i.e., HtFE2, HtFE4, and HtFE5, with significant improvements over baseline methods. Compared with eight federated learning algorithms, FedPSS maintains high accuracy while achieving low communication overhead and striking a favorable balance between overall performance and resource consumption. In summary, the two proposed algorithms provide efficient solutions for federated learning in scenarios with dual heterogeneity of data and model.

Key Words: heterogeneous federated learning; personalized federated learning; data heterogeneity; model heterogeneity

目 录

摘要	I
Abstract	III
1 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.3 本文研究工作	8
1.4 本文的组织结构	9
2 基础知识	11
2.1 联邦学习	11
2.2 数据异构性	15
2.3 模型异构性	16
3 基于类内聚合与双重自适应调整的异构联邦学习算法	18
3.1 研究动机	18
3.2 问题定义	19
3.3 FedIADA 算法架构	20
3.4 实验设置	28
3.5 实验评估	34
3.6 本章总结	42
4 基于原型放缩和步长衰减聚合的异构联邦学习算法	43
4.1 研究动机	43
4.2 问题定义	44
4.3 FedPSS 算法架构	44
4.4 实验设置	51
4.5 实验评估	53
4.6 本章总结	63
5 总结与展望	64
5.1 工作总结	64

5.2 未来展望	65
参考文献	66
在学期间发表论文的清单	75
致谢	76

图目录

图 2-1	FedAvg 算法流程	13
图 3-1	客户端模型框架	20
图 3-2	FedIADA 模型整体框架	21
图 3-3	类内加权聚合示意图.....	23
图 3-4	Fashion-MNIST 和 CIFAR-10 数据集病态样本分布 (20 个客户端).....	30
图 3-5	类别客户端分布矩阵.....	31
图 3-6	Fashion-MNIST 和 CIFAR-10 数据集实际样本分布 (20 个客户端).....	32
图 3-7	CIFAR10 数据集下 FedIADA 及各算法收敛曲线	40
图 4-1	FedPSS 模型整体框架	46
图 4-2	原型放大示例	46
图 4-3	双层对比学习示意图.....	49
图 4-4	不同方法特征可视化对比	58
图 4-5	CIFAR10 数据集下 FedPSS 及各算法收敛曲线.....	59
图 4-6	FedPSS 不同损失组合下的特征空间可视化对比	62

表目录

表 3-1	FedIADA 所用符号表	20
表 3-2	图像数据集基本信息	29
表 3-3	病态分布基本信息	30
表 3-4	模型异构设计	33
表 3-5	实验环境配置	34
表 3-6	实际数据分布下各算法准确率 (HtFE2)	35
表 3-7	病态数据分布下各算法准确率 (HtFE2)	36
表 3-8	实际数据分布下各算法准确率 (HtFE4)	37
表 3-9	实际数据分布下各算法准确率 (HtFE5)	38
表 3-10	FedIADA 及各算法计算与通信成本对比	39
表 3-11	FedIADA 关键模块消融实验结果	40
表 3-12	类内聚合消融实验结果	41
表 3-13	全局融合超参数 λ 不同取值对 FedIADA 算法性能影响	42
表 3-14	自适应 logits 调整的 β 不同取值对 FedIADA 算法性能影响	42
表 4-1	FedPSS 所用符号表	45
表 4-2	实际数据分布下各算法准确率 (HtFE2)	53
表 4-3	病态数据分布下各算法准确率 (HtFE2)	54
表 4-4	实际数据分布下各算法准确率 (HtFE4)	55
表 4-5	实际数据分布下各算法准确率 (HtFE5)	56
表 4-6	FedPSS 及各算法计算与通信成本对比	59
表 4-7	FedPSS 关键模块消融实验结果	60
表 4-8	客户端双层对比学习消融实验结果	61
表 4-9	原型放缩超参数 μ 不同取值对 FedPSS 算法性能影响	62
表 4-10	双层对比学习超参数 λ 不同取值对 FedPSS 算法性能影响	63

1 绪论

1.1 研究背景与意义

在大数据时代，边缘设备会不断产生海量数据，包括移动终端所拍摄的图像、用户交互产生的文本、智能设备捕获的行为信号等。随着 5G 技术的普及与边缘计算能力的提升，这些数据为人工智能的发展提供了新的支持。但是，传统集中式机器学习在面对现实场景时会逐渐出现一些局限性^[1,2]。一方面，边缘数据呈现指数级增长，这受限于网络带宽波动与连接的不稳定性，客户端将全量数据传回中心服务器会变得越来越困难。另一方面，数据保护法规的相继出台^[3-5]，使得用户数据的敏感性进一步提高，数据泄露不仅会损害个人的隐私，还可能让商业信誉受损甚至引来法律风险。若继续使用数据集中采集与处理的传统模式，将难以满足相关隐私法规的要求，同时，频发的隐私泄露事件也在加剧公众对数据滥用风险的担忧。以医疗健康领域为例，患者的影像资料、电子病历等敏感数据分散在不同机构，这些隐私数据受到监管限制，传统框架难以实现合规的共享与联合建模。可以说，如何在数据价值挖掘与隐私安全保护之间寻求平衡，构建一条可信的技术路径，已成为学界与产业界所要共同面对的核心命题。

在这个背景下，谷歌提出的联邦学习框架^[6]提供了一种新的解决思路。该方法在确保原始数据留存于本地客户端的同时，协调分布式节点共同训练全局模型。具体而言，中央服务器初始化全局模型并分发到各个参与的客户端中。各客户端利用本地数据独立训练模型，仅将模型的更新量而非原始数据回传至服务器。服务器通过聚合算法融合各客户端的更新，生成新一轮全局模型，并开始下一轮的迭代。联邦学习从源头上避免了敏感数据的直接传输与集中存储，既保障了数据主体的隐私权益，也契合了隐私保护法规的要求。正因如此，医疗诊断^[7]、金融风控^[8,9]、智能物联网^[10]等数据敏感领域的跨设备协同建模中，联邦学习逐渐被视为兼顾安全性与可扩展性的可行方案。

尽管联邦学习在理论和应用层面已取得不少进展，但真要部署到实际场景中，异构性和通信效率依然是构成其落地应用的核心瓶颈^[1,11]。具体来说，挑战主要体现在以下几个方面：

(1) 数据异构。不同用户的行为模式，使用习惯以及地理分布等因素的多样性，这些因素导致各客户端的数据分布在实际中呈现非独立同分布（Non-Independent and Identically Distributed, Non-IID）特性^[12]。这种统计上的偏差，会让本地模型的更新方向与全

局模型更新方向不一致，拖慢全局模型的收敛速度，影响模型泛化能力^[13,14]。

(2) 模型异构。在实际部署中，受到硬件性能差异和知识产权保护的影响，各客户端本地模型通常采用不同的结构，而非传统联邦学习所假定的统一架构。这种模型层面的异构性使得传统的参数加权平均聚合的方法难以直接适用^[15,16]，需要设计能够实现异构模型间知识迁移的通信机制。同时，模型结构和参数规模的不同还提高了系统的复杂度，对模型的收敛稳定性提出了更高要求^[11]。

(3) 高额的通信成本。联邦学习在模型训练过程中需高频次传输模型参数或梯度更新，具有通信轮次多且单次传输数据量大的特点，使得通信开销成为制约其规模化部署的关键瓶颈^[2,17]。对于那些资源受限的边缘设备，传统联邦学习的大规模数据交换并不现实。如何在保证模型性能的前提下降低通信频率、压缩传输数据量，已成为当前研究的热点问题。

上述由于异构性引发的多重困境，不仅影响联邦学习的训练效率与模型性能，也制约了其在真实场景中的落地与应用。因此，在数据和模型双重异构的约束下，设计高精度且低通信开销的联邦学习算法，是解决当前资源受限环境下性能瓶颈的关键，对于构建高效、鲁棒且可扩展的分布式学习体系具有重要价值。通过上述分析，本研究的主要贡献与意义体现在以下两个方面：

(1) 本文致力于数据与模型双重异构下的联邦学习算法研究。本文所提算法能够适应现实应用中客户端数据分布差异与模型结构差异并存的实际场景，有效缓解双重异构带来的性能损失，提升模型的判别能力、个性化适配能力与泛化表现。

(2) 本文聚焦于数据与模型双重异构下降低联邦通信开销的方法研究。该研究旨在牺牲模型精度的前提下减少通信量，为资源受限场景下的大规模联邦学习部署提供可行的解决方案。通过降低通信成本，可进一步放松联邦学习参与设备的通信条件，推动联邦学习技术在边缘计算、物联网等低通信资源场景中的普及应用。

1.2 国内外研究现状

1.2.1 数据异构

传统联邦学习（如 FedAvg^[6]）假设各客户端数据都是独立同分布的，但是真实场景中数据往往呈现非独立同分布特性，导致 FedAvg 性能显著下降^[13,18]。为应对这一挑战，现有方法主要从数据层面和模型层面展开研究^[11,19]。数据层面的方法通过调整本地数据分布来增强全局模型的性能；而模型层面的方法则聚焦于改进联邦学习算法本身，通过对模型参数或输出进行约束与聚合优化，在不改变数据分布这一前提下提升模型在数据

异构环境下的泛化能力和收敛性能。

数据层面的方法常见手段可分为数据增强以及数据清洗。数据增强的目标在于削弱数据分布的异构性，通过提升数据的均匀程度来缓解客户端间的分布偏差。Chen 等人提出了 FRAug^[20]，这是一种面向特征空间的增强方法，该方法在服务器端学习一个共享嵌入生成器，用以提炼来自各客户端的全局共识。客户端则把该生成器输出的合成嵌入转换为本地专属的表示，以此做到在不暴露原始数据的前提下扩展训练空间的多样性。StatMix^[21] 由 Lewy 等人提出，利用统计特征增强联邦场景下的模型泛化能力。与此同时，生成对抗网络也被广泛引入联邦增强任务。Xin 等人提出了 FL-GAN^[22]，结合了 Lipschitz 约束，在保障数据隐私的同时生成高质量的合成样本。为解决本地数据重叠不足的问题，Zhang 等人提出了 FedDA^[23]，该方法通过从有限重叠和大量非重叠数据中联合学习特征，生成更多重叠样本以扩充训练集。在标签噪声环境下，通过数据清洗来增强联邦学习的鲁棒性，Chen 等人^[24] 提出了一种基于双网络协同优化的方法。边缘设备能够在含有噪声标签的数据集中自适应地学习局部损失权重，并通过与中央服务器的协同更新机制调整全局权重，从而在缺乏纯净数据集的条件下实现对噪声样本损失函数的有效重加权。FED-DR-Filter^[25] 则是另一种思路，它利用全局数据表示之间的相关性，从含噪数据中把不可靠的样本过滤掉筛选出相对可信的样本。

第二类基于模型的方法，可以进一步将这些方法划分为参数解耦、知识蒸馏和联邦优化三类。参数解耦的核心思想是将模型参数分解，依据解耦粒度的差异，现有方法可划分为多个层次：一部分研究仅将模型区分为主干网络与分类头两部分，而另一些工作则实现更细粒度的层级、通道解耦。为缓解数据异构性问题，Arivazhagan 等人提出的 FedPer^[26] 就是为了缓解数据异构性。他们把全局模型分成基础层和个性化层：基础层靠近输入侧，在各客户端之间共享和传输；个性化层则留在本地，负责实现定制化。这种设计除了应对数据异构，对任务异构和通信异构也有一定帮助。基于“联邦学习各参与方的数据虽在特征层面存在共享结构，但在标签分布上常呈现显著差异”的观察，FedRep^[27] 将模型拆解为表示提取器部分与分类头。客户端通过联邦方式协同训练全局特征提取器，并通过在特征提取器中得到特征表示在本地训练各自的分类头，从而实现个性化。Shen 等人提出的 CD2-pFed^[28] 通过通道级解耦实现细粒度个性化，该方法引入可学习的个性化权重对各层通道进行动态调控，同时设计了循环蒸馏机制，在本地模型与全局模型之间进行双向的知识迁移，以此来缩小解耦通道间的语义差异。

知识蒸馏从教师模型中提取知识，并把知识传递给学生模型，该过程通常要求学生模型的输出接近教师模型^[29]。Li 等人提出的 FedMD^[15] 通过公共数据集上的知识蒸馏实

现安全知识共享, FedGen^[30] 通过服务器训练轻量级生成器合成特征, 并将其分发至客户端进行数据增强, 从而实现无需公共数据集的异构联邦学习知识迁移。而 FedDistill^[31] 则采用分组蒸馏策略, 依据样本丰度差异化迁移知识以强化少数类学习。FedKDDC^[32] 通过引入类别分布约束优化个性化聚合权重, 并利用全局模型对本地模型进行知识蒸馏。

部分研究工作通过在联邦优化流程中融入辅助机制, 提升模型对本地或全局数据分布的适配能力。基于模型层面分为三类代表性联邦优化策略: 正则化、多任务学习与元学习。在客户端的本地训练目标中引入正则化项, 约束模型更新的方向。FedProx^[33] 就是一个典型例子, 它通过近端项限制本地模型不要偏离全局模型太远。FedCurv^[34] 和 FedCL^[35] 利用弹性权重巩固技术防止遗忘跨客户端知识。pFedME^[36] 与 Ditto^[37] 直接借助 L2 正则化将个性化模型拉向全局模型。FedLF^[38] 通过动态调整 logits 缓解了长尾分布下的类别偏差问题, 但其多数类调整系数恒定, 使各客户端过度强化自身本地多数类, 加剧了客户端间的模型漂移。Smith 等人提出的 MOCHA 算法^[39] 将联邦多任务学习应用于数据异构场景, 将各客户端的优化视为独立任务, 并借助惩罚项建模任务间关联。然而, 该算法在实际部署中存在明显局限: 要求所有客户端全程参与, 难以应对大规模或不稳定的客户端环境。元学习在联邦学习中常用于训练一个易于微调的初始模型。例如, PeFLL^[40] 服务器端部署了一个超网络, 该网络以各客户端的描述符作为输入, 并据此生成对应的个性化模型参数。但问题在于, 当需要生成的模型规模比较大时, 超网络需要输出的参数数量会急剧增加, 实际构建和训练难度将会上升。

此外, 为了解决全局模型难以同时适配所有客户端的本地分布的问题。FedALA^[41] 通过引入自适应聚合机制, 为每个客户端学习个性化的聚合权重, 动态调节全局模型与本地模型的融合比例。FedAS^[42] 通过本地模型与全局模型对齐的方式, 为每个客户端生成个性化的模型参数。然而上述方法仅面向数据异构场景, 尚未考虑数据与模型双重异构场景。

1.2.2 模型异构

上述方法虽然有效缓解了数据异构问题, 但现有方法大多假设所有客户端采用相同的模型架构, 这在现实场景中往往难以满足^[11,43,44]。一方面, 客户端设备的硬件配置(如计算能力、内存、通信带宽)存在显著差异, 轻量级设备难以支持复杂模型, 而高性能设备如果使用小模型则会造成资源浪费; 另一方面, 部分客户端出于知识产权保护或商业机密的考虑, 不愿公开他们自己专有模型结构^[45]。基于这些现实因素, 异构联邦学习(Heterogeneous FL, HtFL)应运而生^[46,47], 它允许客户端根据自身硬件条件和隐私需求

定制个性化模型架构，同时通过特定的知识迁移机制实现跨客户端的协同训练。

异构联邦学习需要同时应对数据分布与模型架构的双重异构。它允许各客户端根据自身的硬件条件与隐私需求，定制个性化模型，这既满足了差异化需求，又因为模型结构不一致、参数无法直接聚合，而在保护数据隐私和模型知识产权方面形成了天然优势。不过，随着模型规模不断扩大，直接传输完整参数会带来明显的通信开销。现有模型异构方法提出了多种应对策略^[11,48]，主要包括参数解耦、知识蒸馏、相互学习、模型参数压缩以及基于原型的方法。

第一种基于参数解耦的方法。Liang 等人提出的 LG-FedAvg^[49] 将模型拆分为本地特征提取器与全局分类头两部分。客户端拥有自主设计的异构特征提取器，参数保留本地以保护隐私；所有客户端共享同构分类头，仅上传分类头参数进行加权平均聚合。客户端接收更新后的全局分类头替换本地版本，并独立训练更新模型，使本地模型适配全局分类头，在保护隐私的同时实现跨客户端知识融合。FedGH^[50] 各个客户端之间采用同构分类头，与 LG-FedAvg 区别在于本地训练后上传各类别平均特征表示至服务器，服务器利用这些特征独立训练全局分类头。为在模型异构时实现个性化，pFedHR^[51] 中服务器在每轮迭代中逐层分解并依据层级结构特征完成归类组合，然后通过选取不同分组中的模块重新组装候选模型，并通过公共数据集进行参数微调。FedSSA^[52] 提出了一种基于语义信息的分类头聚合策略。该方法在服务器端进行全局更新时，充分挖掘分类头中蕴含的类别语义，通过对同类分类头参数进行聚类与整合，构建出更具判别性的全局分类头。但该方法仅依据类别语义进行聚合，忽视了客户端在各类别上的分类质量差异以及客户端间数据量的不均衡，导致聚合结果易受低质量更新或小样本客户端的干扰。

第二种基于知识蒸馏的方法。知识蒸馏试图通过迁移模型输出或中间表征来实现更灵活、更轻量级的异构知识交互。Li 等人提出了 FedMD^[15]，各客户端首先基于公共数据集生成私有模型的软标签，并将软标签上传至服务器进行聚合从而形成共识输出。随后，客户端将该共识作为教师模型的输出，通过在公共数据集上进行知识蒸馏，将教师知识迁移至各自的私有模型。完成蒸馏后，各客户端在本地私有数据集上进行少量轮次的微调训练，从而实现知识的安全共享。该机制不仅有效保护了客户端模型结构的隐私，也避免直接传输模型参数所带来的安全风险。在此基础上，Chang 等人提出的 Cronus 框架^[53] 进一步考虑在知识聚合过程中可能存在的攻击行为，通过优化聚合策略提升了系统的鲁棒性。FedGen^[30] 通过服务器训练生成器从客户端分类层中提取全局知识，并将其蒸馏至客户端以指导本地训练。FedDistill^[31] 通过全局分类器增强本地特征的泛化能力，利用全局特征矫正本地分类器的偏差，并对齐全局与本地模型的输出。其核心在于

分组蒸馏策略，即依据本地各类别的样本丰度将类别划分为真实类、富样本类和少样本类，并赋予差异化权重进行知识迁移，从而针对性强化对少数类的学习。FedKDDC^[32]通过引入类别分布相似性优化个性化聚合权重，使模型更倾向于从分布相似的客户端学习，增强个性化适配能力，同时通过全局模型知识蒸馏，在本地训练中利用 KL 散度对齐全局模型输出。

第三种基于相互学习方法。相互学习鼓励共享的小型共享模型与客户端大型私有模型进行双向知识流动。例如，FML^[54]通过比较代理模型与私有模型在本地数据上的逻辑输出差异来推动知识流动。然而，由于同构模型通常参数量较少、表征能力弱于私有模型，当私有模型向同构小模型学习时，传统蒸馏策略可能因知识传递效率低下而制约私有模型的性能表现。针对这一局限，研究者进一步提出自适应蒸馏调整策略，例如 FedKD^[55]通过动态调节蒸馏权重，在私有模型表现优异时增强学习强度，在性能波动时降低蒸馏影响，从而有效规避不可靠知识的传播，提升异构场景下的协同训练效果。针对早期训练阶段共享小模型不够稳定可能阻碍模型收敛的挑战，FedAPEN^[56]为各客户端学习一个个性化权重，用以动态平衡本地异构模型与同构小模型输出的逻辑信息，从而在客户端层面实现个性化。然而，该方法对所有样本采用统一权重，难以适应同一客户端内不同数据间的特征差异。为解决这一问题，pFedAFM^[57]引入了针对每个样本独立训练的可学习权重向量，在特征表示层面实现自适应融合，从而更精细地捕捉数据内部的多样性。具体来说，客户端维护两个模型：一个结构可自由设计的本地异构模型，以及一个所有客户端共享的全局同构小特征提取器，二者共用同一个本地分类头。分别用共享的特征提取器和本地特征提取器提取出两种特征，并通过一个可训练的权重向量把这两种特征进行加权融合，以动态平衡全局知识与本地知识。融合后的特征经本地分类头得到预测结果，计算损失后同步更新本地模型参数和权重向量。紧接着客户端冻结分类头，单独训练全局同构特征提取器。最后将更新后的本地同构小型特征提取器上传至服务器进行加权聚合。相互学习方法的缺点在于它需要客户端同时存储大、小两个模型，这会导致内存占用较大。与此同时每轮通信需要传输同构小模型的模型参数，通信成本较大。

第四种基于模型参数压缩的方法。Chen 等人提出 Fed-QSSL^[58]，客户端采用自监督学习挖掘本地数据特征以应对数据异构，同时通过低位量化压缩模型更新以满足设备资源约束，服务器对量化更新进行反量化、加权聚合与再量化，最终生成既适配本地数据分布又符合各客户端硬件资源的个性化模型。FedRAL^[59]客户端将全局角度矩阵与本地特征相乘生成增强表征，用于分类训练并同步更新模型和矩阵。上传前，客户端对矩阵

进行自适应对角稀疏化以降低通信量。但是这种稀疏化的方法可能导致信息的缺失。

第五种基于原型的方法。基于原型的联邦学习算法通过共享类原型而非模型参数来实现知识协作。FedProto^[47] 作为代表性方法，通过在客户端之间共享各类别的特征均值（即类原型）而非模型参数来实现知识协作。服务器聚合这些原型以形成全局原型，并将其发回客户端，用于指导本地模型的训练。类似的 FedTGP^[60] 也采用原型策略，通过自适应边际增强对比学习来迭代优化全局原型：该机制动态计算当前客户端原型间的最大类间间隔作为边际，在对比损失中同时实现对同类原型的吸引与异类原型的排斥，从而生成语义信息保留且类间可分性更强的全局原型。但该方法的对比学习仅考虑原型与原型之间的交互，缺乏批次内样本间以及样本与原型之间的对比学习，限制了其对本地判别性特征表征的学习能力和全局知识向本地模型迁移的有效性。针对现有原型方法依赖标签传输导致的隐私泄露风险，以及忽视客户端数据质量差异的局限性，FedLFP^[61] 提出了一种隐私保护的改进方案：客户端上传无标签本地原型，并附带其对应的置信度与样本数量作为辅助信息；服务器基于这些信息计算组合权重，通过加权 K-means 聚类生成高质量全局原型。同时通过多维对比学习，在本地强化特征表征，并与全局知识对齐。但该方法样本与全局原型对比学习采用无监督方式，缺乏标签信息引导，可能导致语义错对齐，限制了判别性特征学习与全局知识迁移的有效性。为应对异构联邦学习中全局原型可分性不足的问题，Lee 等人近期提出 ProtoNorm^[62] 算法，通过服务器端的原型对齐将全局原型归一化至单位超球面，使各类原型实现最大角度分离，再通过客户端的原型上采样以缩放因子放大原型，增强其在欧氏空间中的区分度。与此同时，Fang 等人提出的 FedHCL^[63]，客户端首先对本地各类样本特征进行 FINCH 聚类，计算每个子簇的均值作为本地细粒度原型并上传，随后服务器对同一类别的所有本地原型再次聚类，为每个子簇初始化可训练的全局细粒度原型。但上述方法均存在以往历史知识利用不足的问题。

1.2.3 低通信开销的联邦学习

在联邦学习系统中，通信开销已成为制约其可扩展性与实际部署的关键因素之一^[64,65]。客户端与中央服务器之间需频繁交换模型更新，这一过程不仅消耗大量网络带宽，尤其在设备规模庞大或模型复杂度较高时，通信成本往往成为系统性能的主导瓶颈。因此，设计低通信开销的联邦学习方法，对于实现高效、可持续的大规模联邦学习部署具有重要的现实意义。现有研究主要从减少单次通信中传输的信息量和降低全局模型聚合所需的通信轮数两个方向展开。

在降低单次通信传输量的技术路径中, 知识蒸馏与模型参数压缩以及原型是主流方法。其中, 模型参数压缩又可进一步细分为稀疏化、量化两种策略。稀疏化通过识别并保留关键参数, 将冗余参数置为常数, 从而将稠密参数矩阵转化为稀疏形式, 仅传输有效部分以降低通信开销。以 FedRAL^[59] 为例, 客户端在上传前会对全局角度矩阵执行自适应对角稀疏化, 从而实现通信量的有效压缩。与之不同, 量化技术保持参数的稠密结构, 但通过降低每个参数的比特表示来减少传输数据量。典型的如 SignSGD^[66], 仅保留参数的符号位, 大幅压缩通信负载。分解方法则将大型参数矩阵拆解为若干低秩矩阵或向量的乘积形式, 在保证模型性能的前提下显著压缩整体参数量。Sattler 等人^[67] 指出稀疏化对非独立同分布数据更具鲁棒性, 提出稀疏三元压缩方法: 进一步将保留的 top-k 元素量化为总体均值幅度, 仅传输剩余元素。知识蒸馏通过迁移模型输出或中间表征来实现更灵活、更轻量级的异构知识交互。客户端在本地训练后, 在公共数据集上生成软标签, 仅将软标签而非完整模型参数上传至服务器进行聚合。如 FedMD^[15] 和 Cronus^[53], 通过将通信内容从高维参数压缩为低维软标签, 显著降低了单次通信的传输量。针对公共数据集依赖问题, 研究者进一步提出无数据蒸馏方案。例如, FedDistill^[31] 通过上传类别级 logits 均值压缩通信, FedKD^[55] 则结合 SVD 分解在逻辑与表示空间进行蒸馏以降低通信成本。类似地, 基于原型的方法^[47,60-63] 通过上传特征提取器生成的本地原型替代模型参数, 进一步减少传输开销。

降低全局模型聚合所需的通信轮数主要通过增加本地更新轮次与自适应通信调度两种方法。前者通过延长单轮聚合前的本地训练周期, 减少全局交互频率; 后者则根据客户端状态动态调整其参与模式, 进一步规避无效通信。例如, FedAvg^[6] 通过引入本地迭代机制, 显著减少了达成收敛所需的通信轮数。而自适应通信调度方法根据客户端的数据质量、计算能力及网络状态等差异, 动态调整其通信频率或参与决策。例如, 部分工作依据本地损失下降幅度或模型更新的大小, 决定当前客户端是否需要参与本轮全局聚合^[68,69]; 另一些研究则结合客户端选择策略, 优先调度贡献度较高或通信条件较好的设备进行更新^[70,71], 从整体上减少无效通信轮次。两类策略相互补充, 共同推动了通信效率的持续优化。

1.3 本文研究工作

虽然已有研究积累了不少成果, 但在应对数据异构和模型异构双重异构时, 当前主流的联邦学习算法仍有不小的提升余地。本文围绕客户端间数据 Non-IID, 模型部分异构, 和通信成本高昂三个主要开放挑战, 旨在提出一种新的联邦学习算法, 以提升模型

在数据与模型双重异构环境下的整体性能，同时兼顾隐私保护与通信效率。本文的研究工作可概括为下面两点：

1. 提出了一种基于类内聚合与双重自适应调整的异构联邦学习算法 FedIADA (Intra-Class Aggregation with Dual Adaptations for Heterogeneous Federated Learning)。其主要贡献在于：(1) 提出了类内信息聚合全局分类头的策略。该模块为了解决数据模型双重异构中导致的聚合偏差问题，它摒弃传统仅依据样本数量进行加权平均的粗放式聚合方式，服务器端综合考虑客户端在各类别上的样本数量与分类质量，对同一类别在不同客户端的分类头参数进行加权融合，使全局聚合更依赖于高质量本地知识，显著提升全局分类头的判别能力。(2) 构建了自适应聚合本地聚合模块。针对数据模型双重异构中直接替换策略导致本地知识丢失的问题，客户端引入可学习的权重矩阵，在本地动态融合全局分类头与本地分类头，实现全局知识与个性化需求的细粒度平衡，避免简单覆盖带来的知识遗忘。(3) 引入了自适应 logits 调整策略。针对数据异构中类别不平衡导致少数类别学习不充分的问题，基于本地数据分布对输出 logits 进行平滑校准，有效抑制模型对多数类别的过度偏好，增强对少数类别的识别能力与预测公平性。

2. 提出了一种基于原型放缩以及衰减聚合的异构联邦学习算法 FedPSS (Federated Learning with Prototype Scaling and Step-Decay Aggregation)。其主要贡献在于：(1) 提出了原型放缩策略。该策略避免了客户端直接上传各类别样本数量这一统计信息，客户端依据本地数据量对原型进行放大后上传，服务器聚合生成全局原型后再进行相应尺度缩小后下发，在双重异构条件下实现类别数量信息保护与聚合有效性的统一。(2) 提出了步长衰减聚合策略。针对固定步长聚合机制难以融合历史知识、收敛稳定性差的问题，服务器在聚合过程中动态调节聚合权重：训练初期给予所有客户端相对均衡的权重以促进多样化知识探索，随着训练进行逐步降低表现不稳定或贡献度低的客户端权重，增强聚合鲁棒性并加速模型收敛。(3) 引入了双层对比学习策略。客户端在学习全局原型知识的同时，通过对比学习机制加强本地样本的表征质量，进一步提升模型在异构数据下的泛化能力。

1.4 本文的组织结构

本文一共分为五章，论文组织如下：

第一章从研究背景切入，阐述联邦学习的现实意义，并分析了联邦学习的核心价值及其在隐私保护分布式训练中的重要作用。随后，针对数据异构与模型异构问题，系统梳理了异构联邦学习的研究现状与发展动态。最后引出本课题的主要研究内容，并介绍

了全文的整体脉络结构。

第二章主要介绍本文所涉及的基本理论。首先从联邦学习的概念出发，详细解析了联邦学习的基础框架以及 FedAvg 算法的基本原理与工作流程，并介绍了个性化联邦学习。其次详细阐述了传统联邦学习面临的数据异构以及模型异构的挑战，并对数据异构、模型异构的基础知识进行了系统地梳理。

第三章针对数据模型双重异构问题，提出了一种基于类内聚合与双重自适应调整的个性化联邦学习算法 FedIADA。在阐明模型整体架构和执行流程的基础上，依次介绍类内双重加权聚合机制、本地分类头自适应融合策略及基于类别分布的 logits 校准方法。最后，通过多组对比实验与消融分析，全面评估了所提算法在分类准确率、通信效率及异构适应能力方面的性能表现。

第四章针对原型方法在通信效率方面不足，提出了一种基于原型放缩及衰减聚合的异构联邦学习算法 FedPSS 章内详细介绍了模型整体架构以及执行流程。之后系统介绍了基于原型放缩机制、步长衰减聚合策略，以及双层对比学习的实现细节。最后，通过大量的实验，全面评估了所提算法在分类准确率、通信效率及异构适应能力方面的性能表现。另外，该算法只要求客户端共享原型，大幅减轻了客户端的通信负担，因此适用于网络通信受限，同时隐私保护需求较高的联邦学习场景。

第五章对全文研究工作进行了总结和回顾，并展望了异构场景下的联邦学习未来研究方向。

2 基础知识

本章首先阐述联邦学习的基础知识，包括其基本概述与定义，接着引出经典算法 FedAvg 的原理与完整执行流程，并介绍个性化联邦学习。在此基础上，系统介绍数据异构、模型异构的相关知识。

2.1 联邦学习

2.1.1 联邦学习概述

随着人工智能技术的快速发展与深度应用，海量数据已成为驱动模型性能突破的核心燃料。然而，在现实中，有价值的数据往往以“孤岛”形式分散在不同组织、设备或地理区域中^[72, 73]。这一现象主要由两方面因素导致：一方面若是按传统的方法直接收集各个客户端的数据，违反了数据隐私法规^[3-5]的要求；另一方面是技术限制，集中存储海量分布式数据面临巨大的通信开销与安全风险。这种“数据孤岛”现象严重制约了需要大规模多样化数据训练的 AI 模型发展，成为了人工智能进一步发展的关键瓶颈。在此背景下，传统集中式机器学习模式面临严峻挑战：其一是隐私泄露风险^[73, 74]，原始数据在传输与集中过程中极易成为攻击目标；其二是合规成本高昂，数据跨域流动面临复杂的法律审查；其三是模型偏见与泛化能力不足，单一机构数据往往无法代表全局分布。为解决这些矛盾，学术界与工业界迫切需要一种能够在保护数据隐私的前提下实现多方协同学习的新范式。联邦学习正是在这样的背景下应运而生^[6]，并展现出作为关键技术解决方案的独特价值。其核心价值体现在三个维度：在技术层面，它依靠“数据不动模型动”的基本范式，在理论上实现了隐私保护与模型性能的平衡；在合规层面，它为机构间合法合规地借助数据要素提供了技术基础设施^[75]，有助于在满足监管要求的同时释放数据价值；在商业与社会层面，联邦学习创造了新型协作模式，使原本竞争或隔离的实体能够建立多方数据共享机制，共同开发更智能的服务与产品，特别是在医疗联合诊疗、金融风控联盟、智慧城市治理等关乎民生的重要领域^[76-78]，其社会效益尤为显著。

2.1.2 联邦学习定义

联邦学习是一种隐私保护的分布式机器学习框架，其核心目标是在不集中存储或交换原始数据的前提下，协调多个参与方共同训练全局共享模型。在该框架中，多个持有本地数据集的客户端在中央服务器的协调下，一起训练一个共享的机器学习模型。在整

个训练的过程中，任何参与方的原始数据都不会离开其本地控制范围，从而在数据源头确保了隐私安全^[33]。联邦学习通常包含两个阶段的协议具体实现：

(1) 本地模型训练与更新：中央服务器将当前的全局模型参数分发给参与协作的客户端子集。每个选定的客户端在本地选用其私有数据，通过标准优化算法（如随机梯度下降）对模型进行训练，计算出模型参数的更新量（通常表示为梯度或参数差值），而非发送任何原始数据。这一阶段的关键在于，所有涉及原始数据的计算均在数据产生的本地环境完成，从根本上避免了数据泄露的可能路径。

(2) 服务端聚合与全局更新：各客户端将计算更新后的模型信息上传至中央服务器。服务器采用安全聚合算法（以联邦平均算法 FedAvg 及其变种为代表）对这些更新进行融合，进而生成新一轮的、性能改进的全局模型。更新后的全局模型被再次分发，开启新一轮迭代。

通过上述两阶段的循环迭代，联邦学习使得全局模型能够持续吸收并融合分布在多源、多域客户端中的分散知识。随着训练轮次增加，模型性能逐步趋近于将所有数据集中训练所能达到的理想效果。因此，联邦学习不仅是一种分布式机器学习方法，更代表了一种面向数据隐私与安全治理新范式的协同计算架构。它在不移动原始数据的前提下，重新定义了多方在隐私合规基础上协同创造与共享人工智能价值的方式，为数据要素的安全流通与高效利用提供了可行的技术路径。

2.1.3 联邦平均算法

联邦平均算法（Federated Averaging, FedAvg）是由 McMahan 等人于 2017 年提出的联邦学习基准算法，其核心思想是在不集中原始数据的前提下，依靠局部迭代与全局聚合的机制实现模型训练^[6]。设 M 为参与训练的客户端总数， D_i 为第 i 个客户端的本地数据集，其大小为 $|D_i|$ ，所有客户端数据总量为 $N = \sum_{i=1}^M |D_i|$ 。设 ω 为全局模型参数， $F(\omega; x)$ 表示参数为 ω 的模型对输入 x 的预测输出， y 为对应的真实标签。权重系数 $\frac{|D_i|}{N}$ 确保了数据量更大的客户端对全局模型的影响更为显著。因此，联邦学习的全局模型优化目标可以定义为：

$$\arg \min_{\omega} \sum_{i=1}^M \frac{|D_i|}{N} L_i(F(\omega; \mathbf{x}), y), \quad (2-1)$$

式中 $L_i(\cdot, \cdot)$ 表示模型在第 i 个样本上的损失函数。

如图2-1所示，联邦平均算法将每一轮通信迭代划分为四个核心阶段：本地训练、本地模型上传、全局模型聚合以及全局模型下发。假设共有 M 个客户端参与联邦学习系统，第 i 个客户端持有本地数据集 $\mathcal{D}_i$ ，所有客户端数据总量为 N 。 E 为本地迭代轮数，

η 为本地学习率。FedAvg 算法的四个核心步骤详述如下：




图 2-1 FedAvg 算法流程

1. 本地训练：在第 t 轮通信开始时，每个客户端 i 以接收到的全局模型 $\mathbf{w}^t$ 作为本轮本地模型 $\mathbf{w}_i^t$ 的初始值，在本地数据集 $\mathcal{D}_i$ 上独立执行训练并更新模型。更新规则为：

$$\omega_i^{t+1} = \omega_i^t - \eta_i \frac{\partial}{\partial \omega_i^t} \mathcal{L}_i(F(\omega_i^t; x), y), \quad (2-2)$$

完成 E 轮本地参数更新后，客户端得到更新后的本地模型参数 $\mathbf{w}^{t+1}$ 。

2. 本地模型上传：完成本地训练后，每个参与训练的客户端将本地更新后的模型参数 $\mathbf{w}^{t+1}$ 上传至中央服务器。该阶段仅传输模型参数，不涉及任何原始样本数据，从而在通信层面保障用户隐私安全。上传的模型参数携带了客户端本地数据的分布特征与知识信息，是后续全局聚合的关键输入。

3. 全局模型聚合：中央服务器收集所有参与客户端上传的本地模型参数后，执行联邦平均聚合操作。第 $t+1$ 轮更新后的全局模型参数 ω^{t+1} 等于所有客户端本地更新后模型参数的加权平均和。全局模型聚合公式为：

$$\omega^{t+1} = \sum_{i=1}^M \frac{|\mathcal{D}_i|}{N} \omega_i^{t+1}. \quad (2-3)$$

4. 全局模型下发：下一轮通信开始时将全局模型 ω^{t+1} 下发至客户端中。

重复上述四个阶段，全局模型在每一轮通信中吸收各客户端的本地知识，直至模型收敛或达到预先指定的联邦通信轮。FedAvg 依靠上述机制将分布式优化中的计算负载

转移至客户端侧，服务器仅需执行轻量级加权聚合，从而在保障数据隐私的前提下实现高效训练。

FedAvg 算法的完整流程如算法2-1所示，其中第 1 至 8 行为服务器执行的操作，第 10 至 16 行是第 t 轮各参与训练的客户端本地训练的过程。

Algorithm 2-1 FedAvg 算法

输入: 通信总轮数 T , 各个客户端本地数据集 D_i , 本地迭代轮数 E , 本地批次大小 B , 本地学习率 η

输出: 最终全局模型 ω

1: **服务器执行:**

2: **for** 每一个通信轮次 $t = 1, 2, \dots, T$ **do**

3: **for** 每个客户端 $i \in A^t$ **并行地 do**

4: 客户端利用全局模型和本地数据更新本地模型: $\omega_i^{t+1} = \text{ClientUpdate}(i, \omega^t)$

5: 服务器获得客户端 i 的更新后本地模型参数 ω_i^{t+1}

6: **end for**

7: 按照公式2-3加权聚合得到新的全局模型 ω^{t+1} :

8: **end for**

9:

10: **ClientUpdate**(i, ω)

11: 初始化本地模型 $\omega_i \leftarrow \omega$

12: **for** 每一个本地轮次 $e = 1, 2, \dots, E$ **do**

13: **for** 每一个样本批次 $B \subseteq D_i$ **do**

14: 按照公式2-2更新本地模型参数

15: **end for**

16: **end for**

2.1.4 个性化联邦学习

个性化联邦学习 (Personalized Federated Learning, PFL) 旨在为不同客户端生成适配其本地数据分布的个性化模型，在利用全局知识的同时保留本地特性^[79,80]。然而，根据异构性来源的不同——数据分布差异与模型架构差异，现有研究方法呈现出不同的技术路径与设计范式。本节分别对两类场景下的主流方法进行系统梳理与评述。

在应对数据异构挑战的个性化联邦学习中，现有方法主要可分为两类：第一类是局部模型个性化，其核心在于依靠局部微调、正则化约束或多任务学习等机制，允许客户

端在全球模型的基础上发展出适配自身数据分布的差异化模型；第二类是全球模型个性化，侧重于直接训练一个具备内在个性化能力的全局模型，例如通过设计个性化输出层、学习共享的特征表示空间或凭借原型等方法，使模型本身或其输出能天然适应不同客户端。

在应对模型异构挑战的个性化联邦学习中，客户端模型的异构性可根据其结构约束程度划分为模型部分异构和模型完全异构。模型部分异构中客户端模型的主体部分允许采用不同架构，但保留一小部分同构结构作为知识交换的统一接口。客户端借助共享这一同构模块从全局协作中获取通用知识，通常借助模型混合策略解决。模型完全异构则允许客户端自由选择任意模型架构，不施加任何的限制。当前研究主要探索了依据知识蒸馏的软标签传递、依靠互学习实现同构小模型和本地模型间协同优化，以及构建跨客户端的原型表示等方法来实现。

2.2 数据异构性

数据异构性（Data Heterogeneity）表现为不同客户端本地数据的分布存在显著差异，即非独立同分布^[14]。这一特性源于联邦学习分布式架构的内在属性：在跨设备联邦学习场景中，不同用户的行为模式、使用习惯、地理分布、设备类型等因素的多样性，导致其生成的本地数据呈现出天然的非一致性^[33]。以智能手机相册的图像分类任务为例，设想我们要用联邦学习训练一个能识别宠物、食物和风景等类别的模型。现实中，不同用户的拍摄习惯和生活方式，会让他们的本地数据分布差异很大。喜欢户外摄影的人，相册里多是山川、日落等场景；家中有宠物或小孩的用户，照片则以动物和人物为主；而对美食博主来说，几乎都是各种食物的特写。这样的差异积累到全局，就会出现明显的分布偏移。具体而言，数据异构性可细分为多种表现形式：特征分布偏移指各客户端的数据在特征空间上分布不同；标签分布偏移指各客户端本地数据中类别标签的比例不一致；数据质量偏斜则体现在客户端间数据在噪声水平、标注精度或信息完整性等方面的系统性差异；数据数量偏斜描述的是各客户端持有数据总量的悬殊差距，通常符合长尾分布规律。这些多维度的分布差异共同构成了联邦学习算法设计的根本挑战。本文研究的是数据异构中数量偏斜的问题。

与传统分布式学习假设数据满足独立同分布不同，联邦学习场景下的数据异构性对优化过程产生了深刻影响。大量研究^[33,81-83]表明，由于各客户端所持有的本地数据分布存在显著差异，引导本地模型的参数更新趋向于各自的局部最优点，而非全局优化方向，这就会让局部优化目标与系统的全局优化目标之间出现偏离。此外，受到每轮参与

客户端的随机采样及其本地数据异构性的影响，各轮聚合得到的全局模型更新方向存在显著差异，导致模型参数在优化空间中剧烈波动，表现为测试性能随着训练轮次大幅起伏。这种震荡不仅延缓收敛进程，还可能导致模型在局部极值点之间反复跳跃，难以达到稳定状态。使得 FedAvg 等算法的模型准确率以及收敛速度显著下降^[18]。

2.3 模型异构性

现有大多数联邦学习算法假设参与协作的客户端默认为采用统一结构的本地模型，来确保各方的参数可在服务器端直接聚合，进而形成统一的全局模型。然而，这一预设与现实场景往往难以满足：受限于差异化的硬件条件与具体任务的需求，各参与方难以统一采用相同的模型架构——不同的计算能力、存储容量甚至能效约束，这种差异都直接决定了各设备所能承载的模型架构的复杂度范围，这就使得各客户端必须根据自身数据特征以及计算资源选择与之相适应的模型结构^[11,43,84]。例如，部分客户端可能是配备高性能 GPU 的服务器，与充足内存的高端智能手机能够高效运行 ResNet-50 等复杂的深层模型，而其他客户端可能是资源受限的边缘设备，而受限于算力、存储与续航的智能手表及物联网设备则多采用 MobileNet 这类轻量级架构以适应其资源约束。因此，为了让联邦学习真正落地到异构设备环境中，各客户端必须结合自身的数据分布特点与可用的计算资源，自由选择最适合自身的模型结构，而不能被强制要求使用统一的模型架构。与此同时，出于对商业机密与隐私保护策略的考量，客户端通常不愿公开其模型的内部设计细节。以多家医疗机构联合开展医学影像分析为例，它们在保障患者数据隐私的前提下，可能分别采用适配各自诊疗场景的异构模型架构。由此，模型异构联邦学习的核心目标，是在既不交换原始数据、亦不暴露模型结构的前提下，实现知识在不同架构模型间的有效迁移。而模型异构可以根据参与方的模型结构差异程度，将模型异构进一步划分为部分异构与完全异构两种类型^[43,85,86]。

部分异构指各客户端的模型架构共享部分网络结构。特征提取阶段允许根据硬件条件采用不同架构，以适应各设备的算力与存储差异，而分类器结构保持统一。这样一来，服务器可依靠聚合分类器参数，间接融合来自不同客户端的知识。由于仍存在可对齐的共享模块，传统聚合方法在这些模块上依旧可用，同时也可以引入知识蒸馏以及原型等技术，实现跨架构的知识迁移。本文聚焦于模型部分异构场景下异构特征提取和同构分类器的联邦学习方法研究。

完全异构意味着各客户端可以自由选择本地模型架构，参数空间因此无法直接对齐，传统的参数平均聚合方法也随之失效。既然无法在参数层面直接交互，就需要引入与模

型架构无关的知识传递机制，例如知识蒸馏、原型聚合，以及依据小型同构模型的相互学习。知识蒸馏学生模型依靠模仿教师模型的输出概率分布进行训练，从而在保持较高性能的同时，获得更小的模型尺寸以及更快的推理速度；原型聚合则借助统计各类别特征的平均值，在类级别上共享表示信息；而相互学习的思路稍有不同，它先让客户端对齐一个小型同构模型，再借助该模型与本地异构模型相互学习，间接完成知识交换。

3 基于类内聚合与双重自适应调整的异构联邦学习算法

3.1 研究动机

联邦学习作为一种隐私保护的分布式机器学习技术，多个参与方可在不共享原始本地数据的前提下协同训练全局模型。然而，实际部署中普遍存在的数据异构（客户端间数据的非独立同分布）与模型异构（客户端因设备、需求等差异采用不同模型结构）相互耦合的问题，这导致传统学习方法效果不佳。因此，本章聚焦于数据与模型双重异构条件下的联邦学习问题，旨在探索一种能同时适应分布差异与模型结构差异的联邦学习算法，以提升联邦学习在真实复杂场景中的可用性与有效性。其中模型异构的表现形式可根据其结构差异的程度划分为完全异构和部分异构。本文研究的是部分异构场景，其特点在于客户端模型并非整体结构相异，而是各个客户端的特征提取器不一致，分类头则保持结构统一。

现有大多数方法延续了传统联邦平均的思想，仅依据样本的数量进行权重分配，如 LG-FedAvg^[49]，FedProto^[47]。这类方法未能充分考虑不同类别在客户端间的分布不均衡及客户端在各类别上的分类能力差异，导致聚合过程易受低质量更新的干扰，全局模型的判别性能难以提升。尽管 FedSSA^[52] 在聚合时考虑到通过类内的权重聚合同一类别的分类头，但却没有考虑到客户端在各类别上的分类质量信息与客户端间的数据量权重，导致模型性能受限。

与此同时，客户端通常会将服务器下发的全局分类头直接替换为自己的本地分类头，例如 LG-FedAvg^[49] 和 FedGH^[50] 等方法。然而，这种简单替换会覆盖客户端已学习的个性化特征，导致本地知识丢失，且全局分类头难以适应客户端特有的数据分布，难以平衡全局知识与本地个性化需求。FedALA^[41] 通过为每个客户端学习自适应的聚合权重，动态调节全局与本地模型的融合比例，然而该方法主要面向数据异构场景，尚未充分考虑数据与模型双重异构的挑战。相比之下，另一种策略通过知识对齐来融合信息，例如 FedDistill^[31] 在输出层进行蒸馏模仿，FedProto^[47] 则对齐类别原型以传递知识。虽能简单融合全局与本地知识，但未能实现在参数级别对全局与本地知识进行细粒度、自适应的权衡与融合，最终限制了模型在异构环境下的表现。

当前研究在处理联邦学习中数据异构问题时，现有方法普遍依赖标准的损失函数，如交叉熵进行训练，这会导致模型在训练中易过度偏向多数类别，导致对少数类别的学

习不充分，识别性能下降；与此同时，统一的损失函数难以适配不同客户端间的数据分布差异，限制了模型的泛化能力。

针对上述问题，本章提出了 FedIADA (Intra-Class Aggregation with Dual Adaptations for Heterogeneous Federated Learning) 的异构个性化联邦学习算法。针对数据分布与模型架构的双重异构挑战，FedIADA 通过挖掘类内类间信息、融合全局本地知识、增强少数类识别能力来提升模型性能。FedIADA 包括三项关键策略：(1) **类内聚合分类头**。服务端利用类内聚合与客户端间聚合相结合的方法，依据客户端同类别间的样本数量，与分类质量作为权重，使全局融合依赖高质量本地知识，提升双重异构下全局分类头判别能力。(2) **自适应聚合本地分类头**。客户端利用可学习权重矩阵，在本地动态融合全局分类头与本地分类头，实现在双重异构下全局知识与个性化的平衡。(3) **自适应 logits 调整**。基于本地数据分布，对 logits 进行平滑校准，提升模型在数据异构环境下的泛化能力。通过以上的策略，FedIADA 在数据与模型双重异构的环境下，充分利用类间信息并在客户端进行个性化调整，以较低通信成本提升了分类性能。

3.2 问题定义

本章旨在解决数据模型异构双重异构下的联邦学习问题，即在客户端间存在数据分布差异与模型结构异构性的条件下，实现有效的协同模型训练。在联邦学习中，共有 M 个异构客户端参与训练，各客户端 i 持有本地数据集 D_i ，各个客户端本地数据之间的样本类别、特征分布及数据规模上存在差异。所有客户端的样本总量为 $N = \sum_{i=1}^M |D_i|$ 。如图3-1所示，在每个客户端本地，模型结构由两部分组成：一个是异构的特征提取器 $f(\theta_i)$ ，另一个由两层线性层组成的同构分类头 $h(\phi_i)$ 。同时为了保证各模型输出特征维度的一致性以便于后续分类头的聚合，在所有特征提取器后端统一添加了全局平均池化层。客户端本地模型可表示为 $F(\omega_i)$ ：

$$F(\omega_i) = f(\theta_i) \circ h(\phi_i), \quad (3-1)$$

其中符号“ $\circ$ ”表示模型拼接。

本章所研究的问题可表述为：

$$\arg \min_{\{\theta_i, \phi_i\}} \sum_{i=1}^M \frac{|D_i|}{N} \mathcal{L}_i(h(\phi_i; f(\theta_i; x)), y), \quad (3-2)$$

其中 θ_i 为特征提取器的参数， ϕ_i 为分类头参数， $\mathcal{L}_i(\cdot)$ 表示客户端 i 的本地损失函数，用于衡量模型预测 $h(\phi_i; f(\theta_i; x))$ 与真实标签 y 之间的差异。该优化目标旨在通过协同训




图 3-1 客户端模型框架

练所有客户端的本地模型参数 $\{\theta_i, \phi_i\}_{i=1}^M$ ，在保护各客户端数据隐私的前提下，最小化全局加权经验风险，从而在数据模型双重异构的条件下实现高性能的联邦学习。

本章节所用到的相关符号定义详见表 3-1。

表 3-1 FedIADA 所用符号表

符号	简要说明	符号	简要说明
M	客户端总数	ϕ_{class}	类别级分类头参数
C	类别总数	ϕ_{num}	类别级类数量分类头参数
D_i	客户端 i 的数据集	$\phi_{quality}$	类别级分类质量分类头参数
A_c^t	第 t 轮通信中包含类别 c 样本的客户端	ϕ_{client}	客户端级类数量分类头参数
ω_i	客户端 i 的模型参数	ϕ_g	全局分类头参数
α	狄利克雷分布浓度参数	λ	全局融合超参数
T	通信总轮次	W	自适应权重矩阵
E	本地训练总轮数	$adist$	调整后的权重向量
E_a	自适应聚合本地训练轮数	β	logits 调整平滑参数
η_i	客户端 i 自适应局部聚合学习率	L_A	自适应损失函数

3.3 FedIADA 算法架构

3.3.1 整体架构

FedIADA 算法的整体架构如图3-2，由一个服务端和 M 个客户端构成。在客户端本地训练结束后，会把每个客户端的同构分类头，客户端样本数量上传到服务端。为构建全局分类头 $h(\phi_g)$ 与现有忽略类内信息的服务端聚合方法不同，而是通过加权类内信息与类间信息进行加权。在构建全局分类头的过程中，第一步采用类别层次的加权聚合生成类内聚合表示 $h(\phi_{class})$ 。具体地，针对同一类别在不同客户端上的分类头参数，FedIADA 基于各客户端在该类别下的样本数量与分类质量进行加权融合，分别得到基于样本数量

的加权项 $h(\phi_{num})$ 与基于分类质量的加权项 $h(\phi_{quality})$ ，两者进一步结合形成该类别的聚合表示 $h(\phi_{class})$ 。第二步，依据各客户端所拥有的类别总数对分类头整体进行加权平均，得到 $h(\phi_{client})$ ，最后再以一定的比例将 $h(\phi_{class})$ 和 $h(\phi_{client})$ 进行融合，得到全局分类头 $h(\phi_g)$ 并发送给各个客户端。客户端接收到全局分类头之后并不直接替换本地分类头，通过一组本地可训练的自适应权重矩阵，对全局分类头和本地分类头行动态融合，并将融合后的模型作为新的本地分类头，这样能够在保留客户端已有个性化知识的同时，有效吸收全局结构信息，从而提升模型对异构本地数据的适应能力。客户端本地模型由特征提取器与分类头共同构成。为缓解数据非独立同分布带来的类别不平衡问题，客户端通过统计本地样本的类别分布计算得到的调整权重向量，并将其与原始 logits 逐元素加权，强化模型对少数类特征的的关注与判别，从而在保持数据固有分布结构的前提下提升模型对数据非独立同分布的适应能力。随后，客户端基于校准后的 logits 计算损失、更新本地模型参数，并将优化后的分类头上传至服务端，参与全局模型聚合。




图 3-2 FedIADA 模型整体框架

3.3.2 类内聚合

在异构联邦学习中，每轮通信结束后，服务器需对各客户端上传的本地分类头进行聚合，生成全局分类头 $h(\phi_g)$ 并下发给所有客户端。然而，由于客户端数据存在非独立同分布特性以及各个客户端模型异构，导致类别分布偏差及分类能力不一致，给聚合过程带来了显著挑战。现有方法大多依据客户端数量进行加权平均，未能充分挖掘类别间信息的重要性。

针对上述问题，本章提出了一种类内聚合机制，以弥补现有方法在类内信息挖掘方面的不足。该机制从以下两个维度对客户端分类头参数进行融合：首先，基于各客户端在同一类别上的样本数量进行加权，得到基于类内数据量的聚合表示 $h(\phi_{\text{num}})$ ，以增强模型对各类别的判别能力；其次，引入基于分类准确率的类质量加权策略，得到 $h(\phi_{\text{quality}})$ ，在融合类内信息的同时，有效抑制低质量更新对全局模型的负面影响。最终，将两者以等权方式融合，构成类别级分类头，其形式化表达如下：

$$h(\phi_{\text{class}}) = \frac{h(\phi_{\text{num}}) + h(\phi_{\text{quality}})}{2}. \quad (3-3)$$

在此机制下，若某客户端在某一类别上样本量充足且模型预测准确率较高，其贡献权重将得到增强；反之，若样本量虽多但模型预测准确率较低，其影响力将被适度抑制。如图3-3所示，类内加权聚合机制的核心思想是将同一类别在不同客户端上的分类头参数进行分组聚合。以类别 0 为例，客户端 1 和客户端 i 均包含该类别的分类头，服务器会综合类内数量与分类质量来计算它们对类别 0 分类头的贡献权重，并将对应参数进行融合。通过这种类别级的分组聚合方式，服务器能够更精准地挖掘类内信息，有效缓解因客户端数据分布差异带来的类别偏差问题。下文将对 $h(\phi_{\text{num}})$ 和 $h(\phi_{\text{quality}})$ 两个组成部分进行详细介绍。

(1) 类别数量加权

由于各客户端数据具有非独立同分布的特性，每个客户端只包含部分类别且的类别分布都不一致。考虑到不同客户端之间相同的类具有语义信息是相似的，因此 FedIADA 从类别数量维度对各个客户端的分类头进行加权聚合，这样构造的分类头融合了类内语义信息的统一分类头，从而提升了模型的分类性能。具体来说，各个客户端中的分类头采用全连接层实现，它的输入是样本经过特征提取器处理后得到的特征向量，输出则是各个类别对应的原始预测值，这些预测值经 softmax 归一化处理后得到概率分布。分类头中，每个输出神经元对应一个类别，该神经元与上一层的连接权重共同构成该类别的分类参数集合 $\phi_i = \{\phi_i^0, \dots, \phi_i^{C_i-1}\}$ ，即把全连接层参数按照类别维度进行划分，其中 ϕ_i^c




图 3-3 类内加权聚合示意图

代表客户端 i 针对类别 c 对应的分类头的参数，而 C_i 则指代该客户端本地数据集所涵盖的类别总数。

在通信轮次 t 中，服务器首先从参与客户端集合 A^t 中，筛选出所有包含类别 c 的客户端，构成子集 A_c^t 。服务器为类别 c 聚合其分类头参数，聚合的对象是子集内各客户端 i 所持有的第 c 类参数 ϕ_i^c ，聚合过程如下：

$$h(\phi_{\text{num}}^c) = \sum_{i \in A_c^t} \widehat{W}_i^c \cdot h(\phi_i^c), \quad (3-4)$$

权重 $\widehat{W}_i^c$ 为该客户端拥有的类别 c 样本数量 $|D_i^c|$ ，占所有相关客户端中该类样本总数的比例。公式如下：

$$\widehat{W}_i^c = \frac{|D_i^c|}{\sum_{j \in A_c^t} |D_j^c|}. \quad (3-5)$$

(2) 类别质量加权

在现实场景中由于数据分布不均衡，各个客户端采用模型以及计算能力的差异，导致不同的客户端对同一类别的学习质量存在差异。现有方法在类别层面进行聚合时，大多依据样本数量分配权重，并不能充分评估和利用每个客户端在特定类别上学习所得参数的可靠性，导致生成的全局分类头会受到低质量本地知识的影响，从而限制了模型在各类别上的判别精度上限。针对上述问题，本章引入了基于类质量分数的加权聚合策略，把客户端 i 在类别 c 上学习的分类准确率 q_i^c 作为质量指标，由各个客户端本地计算。通过引入质量评估，可有效降低由低质量客户端产生的参数更新对全局模型的负面影响，

使全局分类头的参数更新更倾向于依赖高质量、高确定性的本地知识，从而增强模型的泛化能力。

在每一轮联邦聚合中，首先需要确定参与第 t 轮通信训练的客户端集合 A^t 。对于模型需要处理的每一个类别 c ，筛选出 A^t 中拥有类别 c 样本的客户端，组成该类别特定的客户端子集 A_c^t 。此子集将专门用于类别 c 相关参数的聚合。那么服务器在聚合类别 c 对应的分类头参数时，考虑 A_c^t 中每个客户端的第 c 类参数 ϕ_i^c ，其聚合形式如下：

$$h(\phi_{\text{quality}}^c) = \sum_{i \in A_c^t} Q_i^c \cdot h(\phi_i^c), \quad (3-6)$$

其中权重 Q_i^c 由客户端 i 对类 c 的分类准确率 q_i^c 决定，具体为：

$$Q_i^c = \frac{q_i^c}{\sum_{j \in A_c^t} q_j^c}. \quad (3-7)$$

(3) 全局融合分类头

针对异构联邦学习中数据非独立同分布导致的类别偏差问题，类别级聚合机制虽能有效提升各单类别的判别能力，但其聚焦于类内信息的整合，并不能充分挖掘不同类别在客户端间的潜在关联性。为了更好地保留并利用客户端整体知识结构，FedIADA 算法进一步的融入了基于客户端数据规模的全局参数聚合机制。在这个阶段不再考虑客户端内的具体类别分布，而是直接上传完整分类头参数 $h(\phi_i)$ 作为整体进行加权平均，生成客户端间加权聚合分类头 $h(\phi_{\text{client}})$ 。具体聚合公式如下：

$$h(\phi_{\text{client}}) = \sum_{i \in A^t} \bar{W}_i \cdot h(\phi_i), \quad (3-8)$$

其中聚合权重 $\bar{W}_i$ ，依据客户端本地数据集的样本总量 $|D_j|$ 确定，计算过程如下：

$$\bar{W}_i = \frac{|D_i|}{\sum_{j \in A^t} |D_j|}. \quad (3-9)$$

完成类别级与客户端间两阶段聚合后，得到分类头 $h(\phi_{\text{class}})$ 与 $h(\phi_{\text{client}})$ ，为充分融合两者的优势，引入超参数 $\lambda \in [0, 1]$ 对两者权重进行调节，得到全局分类头 $h(\phi_g)$ ：

$$h(\phi_g) = \lambda \cdot h(\phi_{\text{class}}) + (1 - \lambda) \cdot h(\phi_{\text{client}}). \quad (3-10)$$

服务器会将融合得到全局分类头 $h(\phi_g)$ 下发给客户端，该分类头融合了来自多个客户端的知识，能够为各本地模型提供指导，客户端也能从全局分类头 $h(\phi_g)$ 中学习到各个客户端聚合得到的全局知识。

3.3.3 自适应局部聚合机制

客户端在收到服务器下发的全局同构分类头 $h(\phi_g)$ 后, 传统的联邦学习算法 (如 FedAvg) 采用简单的模型覆盖策略进行客户端初始化, 即服务器将全局分类头下发给客户端后, 直接覆盖其本地分类头。由于客户端本地数据分布存在异构性, 经过多轮本地训练得到的模型已在一定程度上学习并适应了其本地特定的数据分布, 直接使用全局模型覆盖, 相当于丢弃了这些珍贵的且能适应本地分布的个性化知识, 导致模型在客户端的本地数据上出现性能退化。受 FedALA^[41] 启发, FedIADA 引入本地自适应聚合机制。不同于 FedALA, 该机制仅对分类头进行操作, 而非整体模型, 即在替换本地分类头之前, 为每个客户端引入一个可学习的权重矩阵, 动态调整全局模型参数与本地模型参数在客户端个性化过程中的贡献权重, 通过逐元素加权融合实现全局知识与本地特性的平衡。

具体而言, 客户端收到服务器下发的全局分类头后, 并不直接覆盖本地分类头, 而是通过该融合权重, 对上一轮的本地分类头 ϕ_i^{t-1} 与本轮收到的全局分类头 ϕ_g^t 进行逐元素的加权融合, 生成一个新的初始化模型 ϕ_i^t , 实现全局知识和本地知识有效融合。FedIADA 采用逐元素聚合策略融合全局分类头与本地分类头, 而非简单覆盖。其形式化定义为:

$$\phi_i^t = \phi_i^{t-1} \odot W_{i,1} + \phi_g^t \odot W_{i,2}, \quad (3-11)$$

$$\text{s.t. } w_q^1 + w_q^2 = 1. \quad (3-12)$$

其中 $\odot$ 表示哈达玛积, w_q^1 和 w_q^2 分别为聚合权重 $W_{i,1}$ 和 $W_{i,2}$ 中的第 q 个参数。 w_q^1 越接近于 1, 说明在相应参数维度对本地模型采纳程度越高, w_q^2 越接近于 1 则说明对全局模型的信赖越强。然而, 在梯度学习方法中, 受 $w_q^1 + w_q^2 = 1$ 约束的 $W_{i,1}$ 和 $W_{i,2}$ 难以有效学习。因此, 将公式3-11重构为:

$$\phi_i^t = \phi_i^{t-1} + (\phi_g^t - \phi_i^{t-1}) \odot W_i, \quad (3-13)$$

其中 $W_i = W_{i,2} = 1 - W_{i,1}$, 为确保权重参数的合理性, 采用逐元素权重裁剪函数 $\sigma(w) = \max(0, \min(1, w))$ 令所有权重参数满足: $w \in [0, 1], \forall w \in W_i$ 。初始时将 W_i 中每个元素值设为 1, 并在每轮迭代中基于旧的 W_i 进行学习。客户端 i 本地数据集为 D_i , 客户端通过梯度学习方法训练 W_i :

$$W_i \leftarrow W_i - \eta_i \nabla_{W_i} L(\phi_i^t, D_i). \quad (3-14)$$

3.3.4 自适应 logits 调整

在联邦学习场景中，客户端数据往往呈现非独立同分布的特性，各类别样本数量可能存在显著差异。传统的交叉熵损失函数未考虑类别数量差异，这种类别分布不平衡问题容易导致模型过度关注样本量大的类别，从而忽略样本稀少的类别，最终损害模型的整体泛化性能。为解决这个问题，本章引入一种自适应的 logits 调整机制，通过在客户端本地类别权重对分类器输出的 logits 进行动态校准，来增强模型对低频类别的识别能力。与现有方法^[38]使多数类的调整系数固定为 1，这可能导致各客户端过度强化自身的本地多数类。本文提出的机制直接基于绝对样本占比进行校准，不依赖于客户端内部的极值类，对数据分布波动具有更强的鲁棒性，且调整后权重直接反映了该类在本地数据中的真实重要程度，可解释性强。其中 $|D_i^c|$ 表示客户端 i 类别 c 的样本数量， $|D_i|$ 表示的是客户端样本数。随后通过以下公式计算调整权重向量 $adist$ ：

$$adist_i = \frac{|D_i^c|}{|D_i|} \cdot (1.0 - \beta) + \beta \cdot 1, \quad (3-15)$$

$adist_i$ 是权重向量 $adist$ 的第 i 个值，平滑因子 β 是一个超参数，1 则代表单位向量。当 β 接近 0 时， $adist$ 主要是由原始类别分布决定。当 β 趋近于 1 时， $adist$ 中各类别的权重相等。此平滑操作的设计兼顾了两方面目标：一方面，能让客户端保留数据内在的分布特性，不破坏其原有的结构性信息；另一方面，还能通过权重调整引入适度的均衡性，以此提升模型在训练过程中对类别较少的类的关注程度。这有助于提升模型在非均衡数据集上的泛化能力。在客户端 i 本地前向传播过程中，其特征提取器 $f(\theta_i; x)$ 输出为 z_i ，分类头输出原始 logits 为 $z_i \phi_i$ ，其中 ϕ_i 为分类头参数。将计算得到的调整权重向量 $adist$ 与原始 logits 逐元素相乘，得到调整后的 logits：

$$\hat{z}_i = adist \odot z_i \phi_i^T, \quad (3-16)$$

经过调整后，模型损失函数可以表示为：

$$L_A = -\frac{1}{N} \sum_{i=1}^N y_i \log \left(\frac{\exp(\hat{z}_{i,y_i})}{\sum_{j=1}^C \exp(\hat{z}_{i,j})} \right). \quad (3-17)$$

3.3.5 算法描述

Algorithm 3-2 FedIADA 算法

输入： 通信总轮数 T ，各个客户端本地数据集 D_i 与其模型参数 $\{\omega_1, \dots, \omega_M\}$ ，模型由异构特征提取器 $f(\theta_i)$ 与同构分类头 $h(\phi_i)$ 组成

输出： 训练后的个性化模型集 $\{\bar{\omega}_1, \bar{\omega}_2, \dots, \bar{\omega}_M\}$

```

1: 服务器执行:
2: for 每一个通信轮次  $t = 1, 2, \dots, T$  do
3:   服务器确定参加本轮训练的客户端集合  $A^t$ 
4:   服务器接受本轮参与训练的客户端的分类头  $\phi_i, i \in A^t$ 
5:   for 类别  $c = 0, 1, \dots, C - 1$  do
6:     for  $i \in A_c^t$  do
7:       按公式3-4类别级数量加权分类头  $h(\phi_{num})$ 
8:       按公式3-6得到类别质量加权分类头  $h(\phi_{quality})$ 
9:       按公式3-3得到类别级分类头  $h(\phi_{class})$ 
10:    end for
11:  end for
12:  for  $i \in A^t$  do
13:    按照公式3-8得到客户端间加权聚合分类头  $h(\phi_{client})$ 
14:  end for
15:  按照公式3-10加权得到全局分类头  $h(\phi_g)$ 
16:  for 每个客户端  $i \in A^t$  并行地 do
17:    服务器将全局分类头  $h(\phi_g)$  分发给客户端  $i$ 
18:    客户端利用全局分类头和本地数据更新本地模型:  $\omega_i^t = ClientUpdate(i, \phi_g)$ 
19:    服务器获得客户端  $i$  的最新本地分类头  $h(\phi_i)$ 
20:  end for
21: end for
22:
23: ClientUpdate( $i, \phi_g$ )
24: for 每一个本地化轮次  $e_a = 1, 2, \dots, E_a$  do
25:   根据公式3-14计算自适应聚合权重  $W_i$ 
26:   使用逐元素权重裁剪函数  $\sigma(\cdot)$  裁剪权重  $W_i$ 
27:   根据公式3-13计算的本地分类头  $\phi_i^t$ 
28: end for
29: for 每一个本地轮次  $e = 1, 2, \dots, E$  do
30:   for 每一个样本批次  $B \subseteq D_i$  do
31:     根据公式3-17计算损失  $L_A$ 

```

```

32:     更新模型参数  $\bar{\omega}_i \leftarrow \omega_i - \gamma_i \nabla_{\omega_i} L_A$ 
33:   end for
34: end for
35: 将更新后的本地分类头  $h(\phi_i)$  上传到服务器

```

3.4 实验设置

3.4.1 研究问题

本节通过详尽的实验验证了个性化聚合联邦学习算法 FedIADA 的有效性。本章将回答以下针对 FedIADA 算法的研究问题：

1. FedIADA 算法在不同客户端规模、不同数据分布场景、不同模型异构程度以及多个图像数据集上的分类准确率表现如何？FedIADA 与现有联邦学习方法相比，该算法能否取得更优的性能？
2. 除分类准确率外，FedIADA 在通信开销、计算效率及收敛速度等方面，相较于现有异构联邦学习算法表现如何？
3. 框架中的各个模块是否为必要组成部分？若移除是否会影响整体性能？
4. 如何设置 FedIADA 中的全局融合超参数 λ 与自适应 logits 调整超参数 β ，以引导模型达到最优性能？

3.4.2 数据集

本节实验选取图像识别任务作为客户端的本地任务，旨在模拟真实场景下移动端或边缘设备上的智能应用场景。图像识别作为深度学习领域的经典任务，具有计算密集、数据量大、模型结构多样等特点，能够有效评估联邦学习框架在不同任务复杂度下的性能表现。在数据集的选择上，本节选取了 Fashion-MNIST^[87]、CIFAR-10 以及 CIFAR-100^[88] 三个公开图像数据集。三者均为多分类任务基准，在计算机视觉研究中被广泛采用，能够为算法的性能评估提供可靠的对照基准。

通过引入这三个不同难度层次的数据集，本文能够全面评估所提方法在简单、中等和复杂图像分类任务上的表现，涵盖从基础视觉识别到细粒度图像分类的多种场景，从而更深入地分析联邦学习框架在异构数据和多样化任务下的收敛性能、通信效率。针对选用的图像数据集，实验都沿用官方提供的训练集和测试集的划分方式。各数据集的详细信息，包括训练样本数量、测试样本数量、类别总数以及图像尺寸等关键参数，均在表 3-2 中列出。

表 3-2 图像数据集基本信息

数据集	训练集大小	测试集大小	类别数	样本尺寸
Fashion-MNIST	60000	10000	10	28×28
CIFAR-10	50000	10000	10	32×32
CIFAR-100	50000	10000	100	32×32

3.4.3 数据准备

为了构造符合真实场景中数据异构性的本地数据集，本章对公开数据集进行重新划分，旨在为各联邦参与方构建具有非独立同分布特征的本地数据集。为了尽可能贴近实际应用环境中的多样性，本章引入了两种在联邦学习领域被广泛采用的数据异构模拟策略，分别为病态数据 (Pathological) 分布场景^[89] 与实际数据 (Practical) 分布场景^[6]。这两种方法均通过对同一类别的样本进行非均匀采样，并将不同数量的样本划分给不同客户端来实现。由于各客户端在各类别上获得的样本数量存在明显不均衡，这两种划分方式均自然形成了客户端间训练数据量的显著差异，从而有效模拟现实场景中用户数据分布的异构性。

病态数据分布是为模拟联邦学习中客户端数据类别的极端异构现象，旨在模拟真实环境中可能出现的具有挑战性的非独立同分布数据。设数据集包含的类别总数为 C ，限定每个客户端本地仅能持有全部类别中随机选取的 c 个类别的样本，且严格满足 $c < C$ ，从而在类别层面构建客户端之间的非重叠性与数据分布的显著差异性。

对于数据集集中的任意类别 i ，需预先确定持有该类样本的客户端数量 $s^{(i)}$ 。该数量的计算依据如下表达式：

$$s^{(i)} = \frac{M \times c}{C}. \quad (3-18)$$

其中 M 为参与联邦学习的客户端总数。对于类别 i ，随机选择 $s^{(i)}$ 个客户端作为该类样本的持有者。在获得共享类别 i 的客户端索引集合后，需进一步决定该类样本在上述 $s^{(i)}$ 个客户端之间的具体分配方式。为此，先从标准正态分布中独立采样生成一个长度为 $s^{(i)}$ 的随机向量，并通过线性变换将其各分量映射至区间 $[0.3, 0.7]$ 内。再对该向量执行归一化处理，使其各分量之和为 1，所得结果即为各客户端应获得的类别 i 样本的比例权重。最终，依据此权重将类别 i 的全部训练样本随机分配至对应的 $s^{(i)}$ 个客户端。表3-3 展示了在病态分布下各数据集的客户端数量、类别总数及每个客户端持有的类别数。图3-4 展示了在 20 个客户端规模下，Fashion-MNIST 和 CIFAR-10 数据集的一次随

机病态划分结果。

表 3-3 病态分布基本信息

数据集	用户数量 M	类别数 C	每个用户的类别数 c	持有 i 类样本的客户端数量 $s^{(i)}$
Fashion-MNIST	20/50	10	2	4/10
CIFAR-10	20/50	10	2	4/10
CIFAR-100	20/50	100	10	2/5




图 3-4 Fashion-MNIST 和 CIFAR-10 数据集病态样本分布 (20 个客户端)

实际数据分布场景为模拟真实联邦学习场景中普遍存在的数据异构现象，本文引入了一种基于狄利克雷分布 (Dirichlet Distribution) 的 Non-IID 数据划分方法。该方法由 Yurochkin 等人^[90] 提出，并已成为联邦学习生成 Non-IID 数据的常用方法。该方法核心理念在于，对于 C 个类别标签和 M 个客户端，针对数据集中每一个特定类别 i ，分别从狄利克雷分布中独立采样，生成一个长度为客户端总数 M 的概率向量。该向量的每一分量，对应各客户端在类别 i 上应分配的样本比例。通过遍历所有类别，即可构建一个维度为 $C \times M$ 的类别客户端分布矩阵，如图3-5所示。最终依据该矩阵所指示的比例，将属于各个类别的样本逐一分配至相应的客户端，从而完成对整个数据集的非均匀划分。

浓度参数 α 决定着数据异构程度。具体而言， α 的数值大小直接反映了客户端之间的数据分布差异程度。当 α 取值较大时，由狄利克雷分布采样得到的向量内部各分量数值趋于接近，意味着每个客户端都能获得各个类别相对均衡的样本，从而呈现出较弱的




图 3-5 类别客户端分布矩阵

数据异构性。极端情况下，如将 α 设置为 100，数据分布趋于均匀，各客户端的数据分布接近独立同分布。反之，随着 α 值的减小，采样得到的概率向量会变得越发稀疏，导致不同客户端所持有的数据分布差异显著扩大。此时，某些客户端甚至可能仅被分配到一个或极少数特定类别的样本，形成高度的数据倾斜。

为在实验环境中构造符合联邦学习评估要求的数据异构性，本文根据数据集复杂度差异设置了相应的狄利克雷分布浓度参数 α 。对于 Fashion-MNIST 与 CIFAR-10 数据集，将浓度参数统一设定为 0.1，以期在客户端间引入显著的分布差异。而对于 CIFAR-100 数据集，则进一步将 α 的值降低至 0.01，旨在通过更强的数据异构程度来模拟现实中更复杂的数据分布场景，从而考查算法在处理复杂分类任务时的分类能力与收敛稳定性。图3-6展示了在 20 个客户端规模下，Fashion-MNIST 和 CIFAR-10 数据集一次随机划分的情况，每个客户端随机分配到不同类别的样本。

3.4.4 评价指标

为全面评估算法在图像多分类任务中的综合性能，本文采用 Top-1 准确率作为统一的评价基准。作为图像分类领域最直观的核心指标，Top-1 准确率直接衡量了模型对样本所属类别的精确判别能力。在此基础上，本文定义全局性能指标 ACC 为各客户端本地 Top-1 准确率的加权平均值，其中权重由各客户端的训练集样本数量决定。该指标本质上等价于所有客户端在本地测试集上正确预测样本数之和与总测试样本数的比值，其具体计算方式如下：

$$\text{ACC} = \frac{\sum_{i=1}^M \sum_{(x,y) \in \mathcal{D}_i^{\text{test}}} 1(\hat{y}_i = y)}{\sum_{i=1}^M |\mathcal{D}_i^{\text{test}}|}. \quad (3-19)$$




图 3-6 Fashion-MNIST 和 CIFAR-10 数据集实际样本分布 (20 个客户端)

式中, M 表示参与联邦学习的客户端总数, $\mathcal{D}_i^{\text{test}}$ 为第 i 个客户端的本地测试集, $|\mathcal{D}_i^{\text{test}}|$ 则对应其测试样本数量。指示函数 $1(\cdot)$ 在模型预测 $\hat{y}_i$ 与真实标签 y 一致时取值为 1, 否则为 0。上述指标设计兼顾了各客户端数据规模的差异性, 能够客观反映模型在全局视角下的真实性能表现。

3.4.5 模型设计

在联邦学习实际应用中, 客户端之间不仅存在数据分布差异, 往往还受限于硬件配置而采用不同的本地模型结构。为探究这种由模型架构差异引发的异构性对算法性能的影响, 本章采用的是模型部分异构, 即使用异构特征提取器 (Heterogeneous Feature Extractor, HtFE) 和同构的分类头。为量化描述模型异构程度, 定义为 HtFE-X, 其中 X 表示联邦系统中采用的模型架构种类总数。在此基础上客户端与模型架构之间的映射遵循循环分配策略: 第 i 个客户端将被指派第 $(i \bmod X)$ 种模型。该分配方式确保了不同架构在客户端群体中的均匀分布, 同时避免了特定模型集中在某些客户端所带来的偏差。

实验环节从包含六种经典卷积神经网络的模型中选取, 具体包括 FedAvgCNN^[6]、GoogleNet^[91]、MobileNetV2^[92] 以及 ResNet18、ResNet34 和 ResNet50^[93]。为构建不同程度的模型异构环境, 本章设计了三种配置: HtFE2、HtFE4 和 HtFE5, 分别对应 2 种、4 种和 5 种模型架构的组合^[85,94], 详细分配方式见表3-4。值得关注的是, 不同模型在参数量、感受野及特征提取能力上存在显著差异, 这种多样性能够更真实地反映实际联邦场景中客户端硬件异构的特点。

为保证各模型输出特征维度的一致性以便于后续分类层的聚合, 在所有特征提取器

后端统一添加了全局平均池化层。针对不同数据集的图像复杂度与分类难度，特征维度 K 的设置有所区分：对于 CIFAR-10 和 CIFAR-100，设定 $K = 84$ 以保留足够的特征表达能力；而对于图像尺寸较小的 Fashion-MNIST 数据集，则令 $K = 256$ 。上述设计既保证了异构模型在联邦框架下的兼容性，也为后续分析模型异构程度对联邦学习性能的影响奠定了实验基础。

表 3-4 模型异构设计

	FedAvgCNN	ResNet18	GoogleNet	MobileNetV2	ResNet34	ResNet50
HtFE2	✓	✓				
HtFE4	✓	✓	✓	✓		
HtFE5		✓	✓	✓	✓	✓

3.4.6 超参数设置与实验环境

本章对训练过程中的关键超参数进行了统一预设。在本地的更新环节中，所有的客户端都采用随机梯度下降优化器。每个客户端在每轮通信中利用本地数据迭代 2 个轮次，批次内样本容量设置为 64。全局模型通信轮次 T 为 50 轮，客户端 i 学习率 γ_i 和客户端 i 自适应局部聚合学习率 η_i 统一取 0.01。值得注意的是，为了模拟真实场景中客户端不稳定的参与状态，每轮通信并未采用固定的参与比例，而是从 0.6 至 1 的区间内随机抽样确定实际参与训练的客户端集合。客户端在本地对全局分类头进行自适应局部融合的训练的轮数 E_a 设为 1。全局融合超参数 λ 设置为 0.5，自适应 logits 调整超参数 β 设置为 0.9。

实验环境配置如下表3-5。

3.4.7 基线方法

本章将 FedIADA 与 9 种异构联邦学习基线方法进行比较，这些方法涵盖了多种策略。基线方法具体包括：

- 基于模型混合的异构联邦学习方法，如 LG-FedAvg^[49]，FedGH^[50]，FedSSA^[52]。
- 基于知识蒸馏的异构联邦学习方法，如 FedGen^[30]，FedKDDC^[32]。
- 基于互学习的异构联邦学习方法，如 pFedAFM^[57]。
- 基于模型参数压缩方法，如 FedRAL^[59]。
- 基于原型的异构联邦学习方法，如 FedProto^[47]，FedTGP^[60]。

表 3-5 实验环境配置

配置项	具体配置
操作系统	Ubuntu 20.04.4 LTS
Python 版本	3.8.10
深度学习框架	PyTorch 1.11.0
CPU	Intel Xeon Platinum 8255C @ 2.50GHz
GPU	NVIDIA GeForce RTX 2080 Ti
CUDA 版本	11.3

3.5 实验评估

3.5.1 准确率评估

为回答问题 1, 本节实验针对图像分类任务评估了 FedIADA 算法与 9 种基线方法的性能。实验结果如表3-6、表3-7、表3-8和表3-9所示, 其中最优结果以加粗标出, 次优结果以下划线标示。实验涵盖了 20 与 50 两种客户端规模, 并设置 HtFE2、HtFE4 和 HtFE5 三种模型异构场景, 并通过调节狄利克雷浓度参数 α 来控制数据异构程度: FMNIST 与 CIFAR-10 数据集设定 $\alpha=0.1$, CIFAR-100 则设定为 $\alpha=0.01$, 以此构建从相对简单到较为困难的渐进式异构分类环境。表中“AVG”列为各方法在三个数据集上的平均准确率, “ Δ ”则表示该模型相对于 LG-FedAvg 准确率的领先幅度。

为全面评估本章所提方法 FedIADA 的有效性, 本章在实际数据分布 (表3-6) 与病态数据分布 (表3-7) 两种联邦学习典型场景下开展了系统实验。

在 HtFE2 架构下 (表3-6), 当客户端数量为 20 时, FedIADA 平均准确率 86.01%, 较 FedAvg 基准提升 1.77%。与次优方法 FedKDDC 相比, FedIADA 领先 0.67%。当客户端数量扩展至 50 时, FedIADA 的性能优势进一步扩大, 在 CIFAR-100 数据集上达到 81.29% 的准确率, 较 LG-FedAvg 提升 4.96%, 这表明了自适应 logits 调整在类别数多的 CIFAR-100 任务中有效缓解了类别不平衡的问题。而 FedIADA 平均准确率为 87.29%, 领先次优算法 0.80%。

在病态分布场景下 (表3-7), 20 客户端设置中, FedIADA 的平均准确率为 84.33%, 较 LG-FedAvg 提升 0.63%。在 CIFAR10 上达到 88.53%, 高于其他方法。50 客户端高度异构场景下, FedIADA 的优势更为明显。其平均准确率达到 80.11%, 较 LG-FedAvg 提

表 3-6 实际数据分布下各算法准确率 (HtFE2)

HtFE2	算法	FMNIST	CIFAR10	CIFAR100	AVG	Δ
20 客户端	LG-FedAvg, 20-arxiv ^[49]	95.96	84.61	72.14	84.24	/
	FedGen, 21-PMLR ^[30]	96.04	85.62	71.99	84.55	+0.31
	FedProto, 22-AAAI ^[47]	96.25	85.56	<u>73.43</u>	85.08	+0.84
	FedGH, 23-MM ^[50]	95.82	84.35	72.68	84.28	+0.04
	FedTGP, 24-AAAI ^[60]	96.24	85.93	73.37	85.18	+0.94
	FedSSA, 24-IJCAI ^[52]	96.23	85.54	73.31	85.03	+0.79
	FedKDDC, 25-Neural Netw ^[32]	<u>96.59</u>	<u>86.01</u>	73.24	<u>85.28</u>	<u>+1.04</u>
	FedRAL, 25-ICCV ^[59]	96.20	85.85	72.84	84.96	+0.72
	pFedAFM, 25-ICDE ^[57]	96.11	85.90	72.70	84.90	+0.66
	FedIADA (本章)	97.09	86.80	74.15	86.01	+1.77
50 客户端	LG-FedAvg, 20-arxiv ^[49]	96.81	81.59	76.33	84.91	/
	FedGen, 21-PMLR ^[30]	97.00	82.08	78.77	85.95	+1.04
	FedProto, 22-AAAI ^[47]	96.98	82.58	79.50	86.35	+1.44
	FedGH, 23-MM ^[50]	96.43	81.39	78.61	85.48	+0.57
	FedTGP, 24-AAAI ^[60]	96.89	<u>82.81</u>	79.76	<u>86.49</u>	<u>+1.58</u>
	FedSSA, 24-IJCAI ^[52]	<u>97.07</u>	81.77	79.50	86.11	+1.20
	FedKDDC, 25-Neural Netw ^[32]	96.78	82.43	<u>80.01</u>	86.41	+1.50
	FedRAL, 25-ICCV ^[59]	96.72	82.53	79.16	86.14	+1.23
	pFedAFM, 25-ICDE ^[57]	96.78	81.67	78.99	85.81	+0.90
	FedIADA (本章)	97.18	83.39	81.29	87.29	+2.38

升 1.11%，在三个数据集上均取得最优结果，充分验证了其在数据模型双重异构条件下的适应性。

随着异构程度提升至 HtFE4（表3-8），在实际数据分布下，当客户端数量为 20 时，LG-FedAvg 基准的平均准确率从 HtFE2 下的 84.24% 降至 82.44%。在此设定下，FedIADA 仍保持最优性能，平均准确率达到 84.79%，较基线算法提升 2.35%，比次优算法提升了 0.98%。当客户端数量增至 50 时，FedIADA 的性能优势更为明显，平均准确率达到 85.27%，较基线算法提升 2.78%，较次优方法 pFedAFM 领先 0.52%。

在 HtFE5 架构下（表3-9），模型异构程度达到最高。FedAvg 基准在 20 客户端场景下的平均准确率下降至 82.86%，较 HtFE2 下降 1.38%。在此设定下，FedIADA 仍保持最优性能，平均准确率达到 84.29%，较 FedAvg 提升 1.43%。当客户端数量扩展至 50 时，

表 3-7 病态数据分布下各算法准确率 (HtFE2)

HtFE2	算法	FMNIST	CIFAR10	CIFAR100	AVG	Δ
20 客户端	LG-FedAvg, 20-arxiv ^[49]	99.32	87.91	63.86	83.70	/
	FedGen, 21-PMLR ^[30]	99.29	88.04	62.89	83.41	-0.29
	FedProto, 22-AAAI ^[47]	99.31	87.91	64.24	83.82	+0.12
	FedGH, 23-MM ^[50]	99.30	<u>88.26</u>	63.15	83.57	-0.13
	FedTGP, 24-AAAI ^[60]	<u>99.35</u>	88.18	<u>65.04</u>	<u>84.19</u>	<u>+0.49</u>
	FedSSA, 24-IJCAI ^[52]	99.33	87.88	63.33	83.51	-0.19
	FedKDDC, 25-Neural Netw ^[32]	99.32	87.81	64.17	83.77	+0.07
	FedRAL, 25-ICCV ^[59]	99.31	88.04	63.51	83.62	-0.08
	pFedAFM, 25-ICDE ^[57]	99.34	87.80	63.31	83.48	-0.22
	FedIADA (本章)	99.38	88.53	65.08	84.33	+0.63
50 客户端	LG-FedAvg, 20-arxiv ^[49]	99.03	84.04	53.94	79.00	/
	FedGen, 21-PMLR ^[30]	99.13	84.53	53.52	79.06	+0.06
	FedProto, 22-AAAI ^[47]	99.13	84.54	54.10	79.26	+0.26
	FedGH, 23-MM ^[50]	99.06	84.80	55.16	79.67	+0.67
	FedTGP, 24-AAAI ^[60]	<u>99.20</u>	<u>84.96</u>	54.93	<u>79.70</u>	<u>+0.70</u>
	FedSSA, 24-IJCAI ^[52]	99.13	84.24	<u>55.30</u>	79.56	+0.56
	FedKDDC, 25-Neural Netw ^[32]	99.16	84.58	54.21	79.32	+0.32
	FedRAL, 25-ICCV ^[59]	99.13	84.18	53.48	78.93	-0.07
	pFedAFM, 25-ICDE ^[57]	99.06	84.34	53.53	78.98	-0.02
	FedIADA (本章)	99.28	85.36	55.69	80.11	+1.11

FedIADA 在 CIFAR-100 上达到 78.29% 的准确率, 平均准确率 85.73%, 较 LG-FedAvg 基准提升 1.88%。值得注意的是, 在此高度异构场景下, pFedAFM 和 FedRAL 展现出较强的竞争力, 其较基准提升了 1.00% 和 0.89%, 而 FedIADA 平均准确率则比次优算法 pFedAFM 还要高 0.88%。这说明了在类别数多、异构性强的复杂任务中, 三项创新策略的协同优势: 类内信息聚合机制能够更有效地从不同客户端中挖掘和融合类内的知识; 自适应聚合机制使每个客户端根据自身模型结构与数据分布特点学习个性化融合权重; 自适应 logits 调整通过平滑校准抑制模型对本地多数类过度偏好的能力。

3.5.2 通信与计算开销

为探究不同方法在资源效率方面的表现, 即回答问题 2。本节以 CIFAR-10 数据集为测试基准, 在客户端总数 20、迪利克雷参数 $\alpha = 0.1$ 、模型异构配置 HtFE2 的设定下,

表 3-8 实际数据分布下各算法准确率 (HtFE4)

HtFE4	算法	FMNIST	CIFAR10	CIFAR100	AVG	Δ
20 客户端	LG-FedAvg, 20-arxiv ^[49]	95.91	82.38	69.02	82.44	/
	FedGen, 21-PMLR ^[30]	95.94	81.09	69.28	82.10	-0.34
	FedProto, 22-AAAI ^[47]	<u>96.97</u>	82.22	70.40	83.20	+0.76
	FedGH, 23-MM ^[50]	95.55	81.99	68.73	82.09	-0.35
	FedTGP, 24-AAAI ^[60]	96.61	<u>83.63</u>	<u>71.18</u>	<u>83.81</u>	<u>+1.37</u>
	FedSSA, 24-IJCAI ^[52]	96.42	82.57	70.45	83.15	+0.71
	FedKDDC, 25-Neural Netw ^[32]	96.11	82.71	69.99	82.94	+0.50
	FedRAL, 25-ICCV ^[59]	95.39	83.62	70.39	83.14	+0.70
	pFedAFM, 25-ICDE ^[57]	96.31	82.24	70.36	82.97	+0.53
	FedIADA (本章)	97.58	85.31	71.47	84.79	+2.35
50 客户端	LG-FedAvg, 20-arxiv ^[49]	95.10	80.15	72.22	82.49	/
	FedGen, 21-PMLR ^[30]	94.86	80.21	75.09	83.39	+0.90
	FedProto, 22-AAAI ^[47]	95.66	80.68	<u>75.95</u>	84.10	+1.61
	FedGH, 23-MM ^[50]	94.94	79.56	75.75	83.42	+0.93
	FedTGP, 24-AAAI ^[60]	94.52	81.99	75.80	84.10	+1.61
	FedSSA, 24-IJCAI ^[52]	95.13	81.30	76.21	84.21	+1.72
	FedKDDC, 25-Neural Netw ^[32]	95.77	81.73	76.01	84.50	+2.01
	FedRAL, 25-ICCV ^[59]	95.54	82.24	75.79	84.52	+2.03
	pFedAFM, 25-ICDE ^[57]	<u>95.86</u>	<u>82.28</u>	75.50	<u>84.55</u>	<u>+2.06</u>
	FedIADA (本章)	95.87	82.80	77.13	85.27	+2.78

对 FedIADA 与各类基线方法的通信及计算开销进行系统评估。实验结果汇总于表3-10, 涵盖测试准确率、计算耗时、内存占用及参数量传输四项指标。其中, 计算时间分别以 50 轮全局训练总耗时(分钟)和单轮平均耗时(秒)两种形式呈现; 内存消耗指完成 50 轮训练所需的存储空间; 通信开销则从理论分析与实际测量两个维度, 给出每轮通信中单个客户端需传输的参数量。符号 ϕ 代表分类头的参数量, C_i 用以描述第 i 个客户端本地数据包含的类别数目, C 代表全局数据集的类别总和, P 则代表了样本特征的维度数。此外, G_m 表示 FedRAL 的表征角矩阵。 G_ω 与 G_θ 分别表示 FedGen 所需的生成器参数量和 pFedAFM 所需的小型同构模型参数量。

从分类准确率来看, FedIADA 以 86.80% 的优于其他所有对比方法, 较 LG-FedAvg 基线提升 2.19%, 与同样取得较高准确率的 FedKDDC (86.01%) 和 FedTGP (85.93%) 相

表 3-9 实际数据分布下各算法准确率 (HtFE5)

HtFE5	算法	FMNIST	CIFAR10	CIFAR100	AVG	Δ
20 客户端	LG-FedAvg, 20-arxiv ^[49]	96.78	82.23	69.58	82.86	/
	FedGen, 21-PMLR ^[30]	96.75	83.11	71.04	83.63	0.77
	FedProto, 22-AAAI ^[47]	96.70	82.60	70.48	83.26	0.40
	FedGH, 23-MM ^[50]	96.48	82.60	70.68	83.25	0.39
	FedTGP, 24-AAAI ^[60]	96.89	82.88	71.47	83.75	0.89
	FedSSA, 24-IJCAI ^[52]	96.70	82.98	<u>71.65</u>	<u>83.78</u>	<u>0.92</u>
	FedKDDC, 25-Neural Netw ^[32]	<u>96.91</u>	83.04	70.37	83.44	0.58
	FedRAL, 25-ICCV ^[59]	96.78	<u>83.12</u>	70.84	83.58	0.72
	pFedAFM, 25-ICDE ^[57]	96.39	83.05	71.38	83.61	0.75
	FedIADA (本章)	97.05	83.70	72.12	84.29	1.43
50 客户端	LG-FedAvg, 20-arxiv ^[49]	95.38	80.13	76.04	83.85	/
	FedGen, 21-PMLR ^[30]	95.42	80.14	76.63	84.06	0.21
	FedProto, 22-AAAI ^[47]	95.30	79.95	77.68	84.31	0.46
	FedGH, 23-MM ^[50]	95.32	79.86	77.29	84.16	0.31
	FedTGP, 24-AAAI ^[60]	95.39	80.36	<u>77.78</u>	84.51	0.66
	FedSSA, 24-IJCAI ^[52]	95.39	<u>80.71</u>	77.44	84.51	0.66
	FedKDDC, 25-Neural Netw ^[32]	95.47	80.19	77.45	84.37	0.52
	FedRAL, 25-ICCV ^[59]	96.40	80.53	77.28	84.74	0.89
	pFedAFM, 25-ICDE ^[57]	<u>96.45</u>	80.64	77.45	<u>84.85</u>	<u>1.00</u>
	FedIADA (本章)	96.77	82.12	78.29	85.73	1.88

比分别领先 0.79 和 0.87 个百分点。在计算时间方面, FedIADA 完成 50 轮全局训练的总耗时为 39.58 分钟, 单轮平均耗时 47.50 秒, 这一数值高于 LG-FedAvg (21.98 分钟) 等轻量级方法, 但低于 pFedAFM (45.87 分钟) 等复杂个性化算法。这表明 FedIADA 在追求更高准确率的过程中付出了一定的计算开销作为代价。在内存消耗方面, FedIADA 与 LG-FedAvg、FedSSA 等多数方法持平, 均维持在 1.35 GB 的水平。FedIADA 在保持较低内存占用的同时实现了最优准确率。从理论分析通信开销层面, FedIADA 的每轮通信量为 $2 \times \phi$, 即仅需上传和下载分类头参数, 与 LG-FedAvg、FedSSA 等轻量级方法处于同一理论量级。这一优势得益于其仅需传输分类头参数的通信策略, 在保证模型性能的同时有效控制了网络带宽占用。而 pFedAFM 需要传输同构模型的实际通信量高达 6840.32 KB。

表 3-10 FedIADA 及各算法计算与通信成本对比

算法	Acc. %	计算时间		内存	通信量	
		总 时间 <i>min.</i>	时间 每轮 <i>sec.</i>	(实际) 总消耗 <i>GB</i>	(理论) 每轮	(实际) 每轮 <i>KB</i>
LG-FedAvg ^[49]	84.61	21.98	26.38	1.35	$2 * \phi$	60.72
FedGen ^[30]	85.62	25.57	30.69	1.26	$G_{\omega} + 2 * \phi$	1185.16
FedProto ^[47]	85.56	31.81	38.17	1.35	$(C + C_i) * P$	5.22
FedGH ^[50]	84.35	30.02	36.03	1.26	$C_i * P + \phi$	5.26
FedTGP ^[60]	85.93	30.95	37.14	1.35	$(C + C_i) * P$	5.22
FedSSA ^[52]	85.54	26.44	31.73	1.35	$2 * \phi$	60.72
FedKDDC ^[32]	86.01	31.82	38.18	1.35	$2 * \phi$	60.72
FedRAL ^[59]	85.85	29.55	35.46	2.25	$2 * G_m$	54.38
pFedAFM ^[57]	85.90	45.87	55.04	1.93	$2 * G_{\theta}$	6840.32
FedIADA	86.80	39.58	47.50	1.35	$2 * \phi$	60.72

3.5.3 收敛曲线

图3-7展示了在 20 个客户端、HtFE4 模型异构场景下，FedIADA 及其他对比算法在 CIFAR-10 数据集上的准确率随通信轮次的变化曲线。FedIADA 在训练初期表现出最快的上升趋势，通信轮次达到 10 轮时准确率已领先于其他对比方法，并在第 25 轮左右趋于收敛。整体而言，FedIADA 在收敛速度和最终精度方面均表现优异，最终稳定在最高水平，且曲线较为平滑、波动较小，充分验证了其在双重异构场景下的性能优势。

3.5.4 消融实验

为深入探究 FedIADA 算法中各核心模块对整体性能的贡献程度，即回答问题 3，选取 CIFAR-10 作为数据集，20 个客户端参与训练，设定迪利克雷参数 $\alpha = 0.1$ ，并采用 HtFE4 模型架构。本节首先从整体层面设计消融实验，逐一移除 FedIADA 所集成的核心机制，观察模型性能的变化趋势，以评估各模块对模型性能的整体贡献。在此基础上，进一步对关键模块的内部组件进行消融分析，深入探究其各子模块的作用。实验结果分别汇总于表3-11和表3-12。

FedIADA 集成了三个核心机制：类内聚合、客户端自适应局部聚合以及自适应 logits 调整。实验构建了四种消融变体：分别移除类内聚合、移除客户端自适应局部聚合、移除自适应 logits 调整，以及同时移除三者 (w/o all)。从表3-11结果可以看出，完整 FedIADA




图 3-7 CIFAR10 数据集下 FedIADA 及各算法收敛曲线

表 3-11 FedIADA 关键模块消融实验结果

损失项	准确率 (%)	Δ 准确率 (%)
w/o 类内聚合	83.37	-1.94
w/o 客户端自适应局部聚合	83.66	-1.65
w/o 自适应 logits 调整	84.17	-1.14
w/o all	82.38	-2.93
FedIADA	85.31	/

模型保持 85.31% 的准确率。移除类内聚合机制后，准确率下降至 83.37%，下降 1.94%，说明了通过融合类内样本分布与分类质量信息，可以提升全局分类头的判别能力。移除客户端自适应局部聚合后准确率下降至 83.66%，下降 1.65%，验证了直接替换全局分类头会导致本地个性化知识丢失。可学习权重矩阵的动态融合策略在吸收全局知识的同时保留了本地特性，提高模型泛化能力。移除自适应 logits 调整后准确率为 84.17%，下降 1.14%，验证了该机制对缓解类别不平衡问题的有效性。值得关注的是，同时移除所有三个模块后准确率进一步降至 82.38%，下降了 2.93%，充分证实各核心模块对整体性能均具有不可或缺的贡献，三者协同作用时能够实现最佳的模型性能。

在类内聚合机制中，类内信息的引入主要体现为两种形式：基于客户端各类别样本数量加权生成的分类头 $h(\phi_{\text{num}})$ ，以及依据客户端数据质量加权得到的分类头 $h(\phi_{\text{quality}})$ 。

为量化各特征对聚类效果及最终准确率的影响, 本文构建了四种消融变体: 移除 $h(\phi_{\text{num}})$ 、移除 $h(\phi_{\text{quality}})$ 、同时移除两者 (w/o both), 并与完整模型进行对比。

表3-12中结果表明, 完整 FedIADA 模型取得了 85.31% 的准确率。移除 $h(\phi_{\text{num}})$ 后, 准确率下降至 84.11%, 降幅为 1.20%, 说明样本数量信息对聚类性能具有正向贡献。移除 $h(\phi_{\text{quality}})$ 后, 准确率下降至 83.90%, 降幅达 1.41%, 表明数据质量信息同样不可或缺。当同时移除两者时, 模型准确率进一步降至 83.37%, 累计降幅达 1.94%。综合来看, 两类权重对模型性能均有较大的贡献, 其中数据质量权重的贡献略高于样本数量权重, 二者协同作用时能够实现最佳聚类效果。

表 3-12 类内聚合消融实验结果

方法	准确率 (%)	Δ 准确率 (%)
w/o $h(\phi_{\text{num}})$	84.11	-1.20
w/o $h(\phi_{\text{quality}})$	83.90	-1.41
w/o both	83.37	-1.94
FedIADA	85.31	/

综上所述, FedIADA 算法中各核心模块及其内部组件均对整体性能具有不可或缺的贡献。类内聚合、客户端自适应融合与 logits 调整三类机制的协同设计, 有效提升了模型在数据与模型双重异构场景下的分类性能与泛化能力。

3.5.5 超参数实验

本小节对问题 4 的进行解答, 即在 FedIADA 算法下如何通过超参数配置实现模型性能的优化。选取 CIFAR-10 作为数据集, 选取 20 个客户端参与训练, 设定迪利克雷参数 $\alpha = 0.1$, 并采用 HtFE4 模型架构开展超参数调优实验。

公式3-10中的超参数 λ 控制类别级聚合分类头 $h(\phi_{\text{class}})$ 与客户端间聚合分类头 $h(\phi_{\text{client}})$ 的融合权重。从表3-13实验结果可以看出, λ 的取值对 FedIADA 算法性能具有较大的影响。当 $\lambda = 0.5$ 时, 模型取得最高准确率 85.31%, 表明此时全局知识与本地知识的融合达到最佳平衡状态。当 λ 偏离最优值时, 模型性能呈现不同程度的下降: $\lambda = 0.1$ 时准确率降至 83.56%, 下降了 1.75%, 说明过小的融合权重导致全局知识利用不足; $\lambda = 1.0$ 时准确率为 84.02%, 下降了 1.29%, 表明过度依赖全局知识会削弱本地个性化适配能力。

在自适应 logits 调整过程中, 通过超参数 β 调节各类别关注度 (公式3-15)。从表3-

表 3-13 全局融合超参数 λ 不同取值对 FedIADA 算法性能影响

λ	0.1	0.3	0.5	0.8	1
FedIADA	83.56	84.23	85.31	84.53	84.02
Δ	-1.75	-1.08	0.00	-0.78	-1.29

14实验结果可以看出, β 的取值同样对模型性能产生重要影响。当 $\beta = 0.9$ 时, 模型取得最佳准确率 85.31%。当 β 偏离最优值时, 模型性能呈现下降趋势: $\beta = 0.7$ 时准确率降至 83.28%, 下降幅度最大, 表明过小的 β 值导致平滑不足; $\beta = 1.0$ 时准确率为 84.17% 下降了 1.14%, 难以有效缓解类别不平衡问题。

表 3-14 自适应 logits 调整的 β 不同取值对 FedIADA 算法性能影响

β	0.7	0.8	0.85	0.9	0.95	1
FedIADA	83.28	84.35	84.65	85.31	84.82	84.17
Δ	-2.03	0.96	-0.66	0.00	-0.49	-1.14

3.6 本章总结

针对现有异构联邦学习方法存在的挑战, 本章提出了一种名为 FedIADA 的异构个性化联邦学习算法。该算法通过在服务端聚合, 全局-本地知识融合及类别不平衡处理来弥补当前研究的不足。在服务端聚合方面, 提出类内聚合机制, 综合考虑客户端在各类别上的样本数量与分类质量, 有效利用类内信息, 构建判别能力更强的全局分类头; 在知识融合方面, 设计自适应聚合策略, 利用可学习权重矩阵动态平衡全局知识与本地个性化需求, 避免直接替换导致的本地知识丢失; 在类别不平衡处理方面, 引入自适应 logits 调整机制, 基于本地数据分布对输出进行校准, 有效提升模型在不均衡数据集上的泛化能力。为全面验证 FedIADA 的有效性, 本章选取了 9 个代表性联邦学习基线模型, 在多种异构程度以及不同数据集上进行系统对比。实验结果表明, FedIADA 在数据与模型双重异构场景下提升了分类性能, 充分验证了所提策略的有效性。然而, 这种高性能的取得依赖于相对充裕的客户端计算资源, 当应用场景转向大规模边缘设备、面临严苛的通信与隐私约束时, 需要更具效率的解决方案。

4 基于原型放缩和步长衰减聚合的异构联邦学习算法

4.1 研究动机

联邦学习中，为应对数据与模型异构性的挑战，现有方法常通过参数共享机制实现协同训练，LG-FedAvg^[49]与FedGH^[50]等方案，借助共享与聚合分类头来完成知识融合。然而，在联邦学习多轮迭代的背景下，持续传输分类头这类参数量较大的模块，将带来显著的通信开销与能源消耗，严重制约该方法在资源受限的边缘环境中的可行性与可扩展性。

为应对联邦学习中普遍存在的数据与模型异构性，并进一步降低模型的通信量，基于原型共享的联邦学习方法（例如FedProto^[47]，FedTGP^[60]与FedLFP^[61]）提供了一种有效的替代路径。该类方法中，客户端仅上传由本地数据计算得到的类别特征均值（即类别原型），而非完整模型参数，每个客户端的原型集仅包含其本地数据中实际存在的类别。服务器聚合来自各客户端的原型以更新全局知识表征，并将其下发指导本地模型更新。这种基于原型的方法不仅降低了通信开销，也赋予了异构架构下知识交互更高的灵活性。

当前服务端原型聚合方法主要面临两方面的显著缺陷。一方面，现有方法为在数据异构条件下实现公平有效的聚合，通常需依赖各客户端为每个类别贡献的样本数量作为加权依据。然而，客户端在上传本地原型时若同步提交各类别的样本数量，相当于将其数据分布概况直接暴露给服务器，可能引发一定的信息泄露风险^[95]。另一方面，现有方法普遍采用固定步长的聚合机制，即使用客户端加权聚合后的结果直接作为全局模型。这会导致模型过度关注当前轮次的局部更新，而未能充分融合历史训练过程中积累的稳定知识。还会在训练后期难以有效抑制因客户端数据与模型异构性所引起的更新偏差，削弱模型的收敛稳定性与性能表现。

针对上述传统联邦学习方法在通信效率、类数量的信息保护及模型性能表现不佳的问题，本章提出了一种新型的基于原型的异构联邦学习算法FedPSS（Federated Learning with Prototype Scaling and Step-Decay Aggregation）。FedPSS旨在保护客户端数据隐私的同时，提升数据和模型双重异构场景下的模型性能与通信效率。具体而言，FedPSS通过引入三种关键策略来系统性地解决现有方法的不足：（1）原型放缩策略。客户端在上传本地模型原型时，不直接暴露其各类别的样本数量，而是在每个客户端根据其样本数

量对本地原型进行放大，客户端分发全局原型进行缩小。(2) 步长衰减聚合策略。服务器在聚合各客户端上传的原型时，在训练初期给予所有客户端相对均衡的权重以促进探索，后期逐步衰减步长，增强历史知识的权重，抑制因客户端异构性带来的更新方向震荡，加速模型收敛，并降低低质量更新的影响。(3) 双层对比学习策略。该策略被应用于各客户端，旨在学习全局原型的知识，同时加强本地样本的表征质量。

4.2 问题定义

本章旨在解决数据模型异构双重异构下的联邦学习问题，即在客户端间存在数据分布差异与模型结构异构性的条件下，实现有效的协同模型训练。在基于原型的联邦学习中，共有 M 个异构客户端参与训练，各客户端 i 持有本地数据集 D_i ，各个客户端本地数据之间的样本类别、特征分布及数据规模上存在差异。所有客户端的样本总量为 $N = \sum_{i=1}^M |D_i|$ 。在每个客户端本地，模型结构由两部分组成：一个是异构的特征提取器 $f(\theta_i)$ ，另一个由两层线性层组成的同构分类头 $h(\phi_i)$ 。同时为了保证各模型输出特征维度的一致性以便于后续分类头的聚合，在所有特征提取器后端统一添加了全局平均池化层。本章所研究的问题可表述为：

$$\arg \min_{GP, \{\theta_i\}, \phi} \sum_{i=1}^M \frac{|D_i|}{N} \mathcal{L}_i(GP, h(\phi_i; f(\theta_i; x)), y), \quad (4-1)$$

其中 θ_i 为特征提取器的参数， ϕ_i 为分类头参数， GP 为全局原型， $\mathcal{L}_i(\cdot)$ 表示客户端 i 的本地损失函数，用于衡量模型预测 $F(\omega_i; x)$ 与真实标签 y 之间的差异。该优化目标旨在通过协同训练各客户端的本地异构特征提取器 $\{\theta_i\}_{i=1}^M$ 、全局共享的分类头参数 ϕ_i 以及全局原型 GP ，在保护各客户端数据隐私的前提下，最小化全局加权经验风险，从而在数据模型双重异构的条件下实现高性能的联邦学习。本章节所用到的相关符号定义详见表 4-1。

4.3 FedPSS 算法架构

4.3.1 整体架构

FedPSS 算法的整体架构如图4-1，由一个服务端和 M 个客户端构成。每轮通信中，客户端首先通过特征提取器将本地样本映射为特征表示，接着对同一类别的特征取均值，得到该类别的原型。不同于现有基于原型的方法，客户端完成本地训练后，不直接上传本地样本数量和本地原型，而是依据本地样本规模对原型进行放大后再行上传，避免了类别信息直接泄露的风险。FedPSS 服务器对接收到的客户端本地原型进行平均聚合，得到初步的全局原型 GP 。随后，采用一种步长衰减策略对 GP 进行加权融合，生成最终

表 4-1 FedPSS 所用符号表

符号	简要说明	符号	简要说明
M	客户端总数	LP_i	客户端 i 本地原型的集合
C	类别总数	$\widehat{LP}_i$	客户端 i 放大后的本地原型集合
A_c^t	第 t 轮通信中包含类别 c 样本的客户端	GP	全局原型的集合
D_i	客户端 i 的数据集	$\widehat{GP}$	对应 LP_i 尺度调整后的全局原型
T	通信总轮次	$\Delta GP^{(t)}$	第 t 轮的全局原型与上一轮全局原型的差值
E	本地训练总轮数	μ	对应 LP_i 缩放超参数
L_i	客户端 i 的损失函数	η_g^t	第 t 轮通信中全局聚合的衰减函数
θ_i	客户端 i 特征提取器参数	γ_i	客户端 i 的学习率
ϕ_i	客户端 i 分类头参数	α	狄利克雷分布浓度参数

的本轮全局原型 $GP^{(t)}$ 。该策略通过动态调节聚合步长 $\eta_g^{(t)}$ 来平衡知识探索与利用：训练初期使用较大的 $\eta_g^{(t)}$ 以快速吸收客户端间的多样化知识，后期则逐步减小 $\eta_g^{(t)}$ 更加注重历史训练过程中得到的稳定的知识，以抑制数据异构引入的更新方向差异，从而提升模型优化的整体稳定性。最终，服务器对 $GP^{(t)}$ 进行尺度调整，得到放缩后的全局原型 $\widehat{GP}$ 并将其下发给各客户端，用于指导本地模型训练。客户端在收到经过放缩的全局原型 $\widehat{GP}$ 后，将利用其优化本地模型。具体而言，客户端一方面通过批次内部的对比学习损失 L_{batch} 来优化决策边界；另一方面，通过全局对比损失 L_{global} 约束本地特征向全局表示学习，从而提升客户端的特征表示能力。

4.3.2 原型放缩

在联邦学习的原型聚合框架中，本文提出了一种原型缩放机制，旨在避免客户端直接上传样本数量信息，降低服务器通过聚合过程推断数据分布的可能性。该机制的核心流程包含三个阶段：客户端原型放大、服务器端聚合与全局原型放缩。

在每一轮通信过程中，客户端 i 通过本地特征提取器将输入的本地样本映射为特征表示，并对同一类别下的样本特征进行均值计算，从而生成该类别对应的本地原型。客户端 i 的第 c 类的本地原型 $lp_{i,c}$ 可由下列公式计算得到：

$$lp_{i,c} = \frac{1}{|D_c^i|} \sum_{(x,y) \in D_c^i} f(\theta_i; x), \quad (4-2)$$

其中， D_c^i 代表客户端 i 数据集中类别 c 的样本集， θ_i 表示客户端 i 的特征提取层参数。

在客户端侧，为减少样本数量这一统计信息的直接暴露，客户端不直接上传原始本地原型及样本数量，而是先根据本地样本数量对原型进行预处理。如图4-2所示，同类样本在特征空间中的分布通常较为聚集，其均值向量（即原型）能够有效表征该类别在特




图 4-1 FedPSS 模型整体框架

征空间中的中心位置。在预处理中，类别原型依据对应类别的样本数量进行放大，样本数量越大，其原型被放大的幅度也越大。这种设计将样本数量信息融入原型中，使得服务器在聚合过程中无需获取各客户端的精确样本数量即可完成加权聚合，即考虑到了各个客户端的样本权重，也降低了数据分布被直接观测的风险。具体而言，客户端 i 类 c




图 4-2 原型放大示例

的本地原型 $lp_{i,c}$ 按其对应类别的样本数量 $|D_i^c|$ 进行放大, 得到本地客户端 i 的原型集合 $\widehat{LP}_i = (\widehat{lp}_{i,1}, \dots, \widehat{lp}_{i,c})$, 其中集合里的每一项为类 c 放大后的本地原型 $\widehat{lp}_{i,c}$:

$$\widehat{lp}_{i,c} = |D_i^c| \cdot lp_{i,c}, \quad (4-3)$$

客户端仅将此缩放后原型集合 $\widehat{LP}_i$ 上传至服务器。由于该操作在客户端本地完成, 客户端无需上传客户端的具体样本数量 $|D_i^c|$, 从通信内容上减少了原始统计信息的直接暴露。

在服务器侧, 服务端在完全无需知晓各客户端具体样本数量的情况下, 对所有客户端上传的放大后原型进行直接平均聚合。假设第 t 轮通信中包含类别 c 样本的客户端集合 A_c^t , gp_c 表示第类 c 的全局原型。全局原型 $GP = (gp_1, \dots, gp_c)$,

$$gp_c = \frac{1}{|A_c^t|} \sum_{i \in A_c^t} \widehat{lp}_{i,c}. \quad (4-4)$$

考虑到在客户端中根据每个客户端的类别数量对本地原型进行放大, 为确保原型在下发至客户端时的稳定性, 为避免聚合后原型数值范围的不稳定, 服务器在分发全局原型前引入一个缩放超参数 μ , 将其与聚合后的全局原型 (此处的全局原型是第 t 轮中, 经过步长衰减聚合策略聚合所得原型 GP^t) 相乘, 得到经尺度调整的全局原型 $\widehat{GP}$, 再分发给各客户端, 具体缩放过程如下:

$$\widehat{GP} = \mu \cdot GP^t. \quad (4-5)$$

原型缩放是针对现有原型方法中加权聚合模块的改进, 旨在解决其简单平均聚合方式所引发的隐私泄露与性能受限问题。在现有方法中^[47,60], 服务器依据客户端上传的各类别及其样本数量进行加权平均聚合; 而原型缩放方法将该加权聚合中的分子部分, 即样本数量与本地原型的乘积移至客户端完成, 从而避免直接传输各类别的样本数量, 降低隐私风险。然而, 由于该操作改变了全局原型的数值尺度, 直接用于正则化约束会导致训练不稳定, 因此引入超参数 μ 进行缩放校准。理论上, μ 的最优取值对应于 FedProto 加权平均中分母, 即同一类别总样本数量的倒数, 但由于每轮参与训练的客户端集合具有随机性, 实际最优值需在该理论值附近通过搜索进行调优。

4.3.3 步长衰减聚合策略

在联邦原型学习中引入全局原型聚合步长衰减策略, 现有方法大多采用固定聚合策略, 即直接计算各客户端本地原型的加权平均作为全局原型, 这种策略过度关注当前轮次的更新, 而忽视了历史多轮训练所积累的稳定知识。在训练后期因放大异构客户端带

来的更新方向的偏差，甚至被少数数据分布极端或样本量偏斜的客户端持续拉扯，从而发生漂移。同时忽视了历史多轮训练所积累的稳定知识的价值，过度关注当前轮次更新，最终往往导致收敛过程不稳定、性能上限受限。

为此 FedPSS 引入步长衰减聚合策略。具体而言，早期采用较大步长以快速吸收各客户端的多样化本地知识，加速初始性能提升并广泛探索由各客户端提供的、分散在特征空间各处的候选原型位置，快速定位潜在的最优类中心区域；随着训练深入，全局模型经验逐渐增加，此时系统性地衰减聚合步长，一方面增强对已形成的全局共识的信任度，另一方面有效抑制因客户端本地局部更新差异所引入的更新偏差，在探索快速学习新知识与利用稳定已有知识之间建立动态平衡，最终在加速早期收敛的同时，保障了后期优化的稳定性与模型的泛化能力。在联邦学习的迭代优化过程中，全局原型采用增量方式进行更新。具体而言，第 t 轮的全局原型 $GP^{(t)}$ 由上一轮的全局原型 $GP^{(t-1)}$ 与当前轮次聚合得到的原型的更新量 $\Delta GP^{(t)}$ 加权组合而成，其中更新量 $\Delta GP^{(t)}$ 定义为当前轮原始聚合原型与上一轮全局原型的差值，全局原型的更新规则为：

$$GP^{(t)} = GP^{(t-1)} + \eta_g^{(t)} \Delta GP^{(t)}, \quad (4-6)$$

其中， $\eta_g^{(t)}$ 表示第 t 轮的全局聚合的衰减函数，用于动态调节本轮更新量对全局原型的影响程度。为在训练的不同阶段实现动态调整，本章引入了基于余弦衰减的步长衰减机制。该机制既保持了历史知识的延续性，又逐步融入来自各客户端的最新局部信息，从而在数据异构环境下实现稳健且高效的全局表征学习。公式如下：

$$\eta_g^{(t)} = \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min}) \left(1 + \cos \left(\frac{t}{T} \pi \right) \right). \quad (4-7)$$

其中 $\eta_{\min}$ 与 $\eta_{\max}$ 分别表示步长的下限与上限， T 为预设的最大训练轮数。该策略使步长随轮次增加按余弦函数从 $\eta_{\max}$ 平滑下降至 $\eta_{\min}$ 。

4.3.4 客户端本地双层对比学习

在对模型进行本地训练时，每个客户端依据服务器分发的全局原型，以交叉熵损失函数与双层对比损失作为优化目标。具体而言，该对比学习由两个部分组成：第一部分，利用批次内的样本进行监督式对比学习，以提高模型对当前客户端特有数据分布的判别能力；第二部分，结合服务器提供的全局原型，实施样本与原型层级的有监督对比学习，通过在特征空间中缩小本地表征与全局原型之间的差异，实现全局知识向本地模型的有效迁移。最终，客户端本地模型的总体损失可通过以下形式化表达式进行描述：

$$L = L_{ce} + \lambda \cdot (L_{batch} + L_{global}), \quad (4-8)$$

其中，交叉熵损失 L_{ce} 衡量模型在分类任务中计算的损失； L_{batch} 为批次内样本间的对比损失； L_{global} 则衡量样本特征与全局原型之间的对比损失。超参数 λ 平衡交叉熵损失与双层对比损失的权重。接下来将介绍对比学习损失项 L_{batch} 和 L_{global} 。图 4-3 展示了该对齐机制， L_{batch} 通过拉近同类样本的表征、推远异类样本的表征，使决策边界更加清晰。类似地， L_{global} 对于全局原型与本地样本，属于同一类的样本就彼此拉近，不同类样本彼此推远。通过这种方式， L_{global} 不仅实现了对全局知识的有效迁移，也增强了对异构本地数据的适应能力。




图 4-3 双层对比学习示意图

(1) 批次内样本对比学习损失 L_{batch}

为提升模型对局部数据分布的判别力，在损失中引入了对比学习损失 L_{batch} ，损失函数的核心目标是使同类别样本的特征表示相互靠近，同时驱使不同类别样本的特征表示彼此远离。在这一目标的驱动下，本地模型的特征提取层能够学习到更具判别性的样本表征，并同步优化本地原型的生成质量。对于批次中的特定样本 i ，其损失项 L_{batch}^i 定义如下：

$$L_{batch}^i = -\frac{1}{|B(i)|} \sum_{b \in B(i)} \log \left(\frac{\exp(\text{sim}(z_i, z_b)/\tau)}{\sum_{j \in B} \exp(\text{sim}(z_i, z_j)/\tau)} \right), \quad (4-9)$$

其中， B 表示当前批次中所有样本的集合， $B(i)$ 表示该批次中与样本 i 属于同一类别的样本子集， z_i 与 z_j 分别表示样本 i 和 j 经过特征提取网络后的嵌入向量， $\text{sim}(\cdot, \cdot)$ 使用点积运算来衡量特征向量之间的相关性， τ 是温度系数，用于调节相似度分布的平滑程度。该损失函数的核心思想驱动同类样本的特征表示相互聚拢，同时让不同类别样本的特征表示彼此远离，进一步提升模型对本地数据分布的判别力。

在这个损失的作用下, FedPSS 能够优化本地特征提取器的参数, 使其生成的特征表示不仅具有更高的质量, 而且能清晰地区分不同类别的语义信息, 从而提升模型的整体分类性能。

(2) 全局原型对比学习损失 L_{global}

全局原型通过汇聚来自各客户端的知识, 扮演着“教师模型”的角色, 为局部模型的学习过程提供关键的知识指导。本算法旨在通过设计特征提取模块, 使生成的样本特征向量在嵌入空间内尽可能接近其所属类别的全局原型, 同时远离其他类别的原型。这种基于原型的特征对齐策略有助于模型更有效地吸收和利用全局知识, 进而增强后续分类决策的准确度与稳定性。

为实现上述目标, 本文为每个样本设计了基于相似性权重的对比损失函数 L_{global} 。与 FedLFP^[61] 中采用的无监督对比损失不同, 本章采用的是有监督对比损失。损失函数引入动态权重调节机制, 该权重依据样本特征与各类全局原型之间的语义相关性进行自适应对齐: 对于相似度高的样本-原型对, 损失函数会增强其对齐约束, 以促进特征表示的聚合; 而相似度较低, 则相应减弱其优化影响。这种策略有效利用全局知识, 加强了本地模型对于全局知识的掌握, 有助于模型训练中建立更具判别力的特征表示结构。其中:

$$L_{global}^i = -\frac{1}{|B(i)|} \sum_{y_i \in B(i)} \text{distance}(z_i, \hat{g}p_{y_i}) \cdot \log \frac{\exp(\text{sim}(z_i, \hat{g}p_{y_i})/\tau)}{\sum_{j=1}^C \exp(\text{sim}(z_i, \hat{g}p_j)/\tau)} \quad (4-10)$$

其中 L_{global}^i 标签为 i 的本地样本与原型之间的对比学习损失。 $\hat{g}p_{y_i}$ 为与样本 i 相同类别标签的放缩后的全局原型。 $\hat{g}p_j$ 是与样本 i 不同类别标签 $j (i \neq j)$ 的放缩后的全局原型。

为更高效地实现本地表征与全局原型的特征对齐, FedPSS 引入了一种加权策略 $\text{distance}(\cdot)$ 。该权重基于样本与原型之间的语义相似度进行动态调整, 对相似度较低的特征对赋予更高权重, 从而使模型在优化过程中更聚焦于当前未充分对齐的困难样本, 提升对齐效率与收敛稳定性。具体实现上采用欧几里得距离 $\|z_i - \hat{g}p_{y_i}\|_2$ 实现。

4.3.5 算法描述

Algorithm 4-3 FedPSS 算法

输入: 通信总轮数 T , 各个客户端本地数据集 D_i 与其模型参数 $\{\omega_1, \dots, \omega_M\}$, 模型由异构特征提取器 $f(\theta_i)$ 与同构分类头 $h(\phi_i)$ 组成

输出: 训练后的模型集 $\{\bar{\omega}_1, \bar{\omega}_2, \dots, \bar{\omega}_M\}$

1: 服务器执行:

2: **for** 每一个通信轮次 $t = 1, 2, \dots, T$ **do**

```

3: 服务端确认参与本轮训练的客户端数量  $A^t$ 
4: 服务端根据4-4聚合客户端本地原型
5: 根据公式4-6采用步长衰减策略聚合得到全局原型  $GP$ 
6: for 每个客户端  $i \in A^t$  并行地 do
7:     服务器根据公式4-5将全局原型进行缩放, 得到  $\widehat{GP}$  并分发给客户端  $i$ 
8:     客户端更新本地模型:  $\omega_i^t = ClientUpdate(i, \widehat{GP})$ 
9:     服务器获得客户端  $i$  放大后的本地原型  $\widehat{LP}_i$ 
10: end for
11: end for
12:
13:  $ClientUpdate(i, \widehat{GP})$ 
14: 计算本地原型
15: for 每一个本地轮次  $e = 1, 2, \dots, E$  do
16:     for 每一个样本批次  $B \subseteq D_i$  do
17:         if  $GP == Null$  then
18:             计算损失  $L_i(B) = L_{ce}$ 
19:         else
20:             根据公式4-8计算损失  $L_i(B)$ 
21:         end if
22:         更新本地模型参数  $\bar{\omega}_i \leftarrow \omega_i - \gamma_i \nabla_{\omega_i} L_i(B)$ 
23:     end for
24: end for
25: 根据公式4-2更新本地原型  $LP_i$ 
26: 根据公式4-3放大本地原型  $LP_i$ , 并将放大后的本地原型  $\widehat{LP}_i$  上传到服务器

```

4.4 实验设置

4.4.1 研究问题

本节通过详尽的实验验证了基于原型放缩和步长衰减聚合的异构联邦学习算法 FedPSS 的有效性。本章将回答以下针对 FedPSS 算法的研究问题：

1. FedPSS 算法在不同客户端规模、不同数据分布场景、不同模型异构程度以及多个图像数据集上的分类准确率表现如何？FedPSS 与现有联邦学习方法相比，该算法能

否取得更优的性能？

2. 除分类准确率外，FedPSS 在通信开销、计算效率及收敛速度等方面，相较于现有异构联邦学习算法表现如何？

3. 框架中的各个模块是否为必要组成部分？若移除是否会影响整体性能？

4. 如何调整 FedPSS 中客户端的对比损失权重 λ 与服务端缩放超参数 μ ，以引导模型达到最优性能？

4.4.2 实验设置

本章实验延续第三章的基本设置：

数据集与数据分布：为评估算法性能，实验在 FMNIST、CIFAR-10 和 CIFAR-100 三个图像数据集上进行分类任务。与第三章相同，分为病态数据分布和实际数据分布，其中实际数据分布的迪利克雷参数 α 在 FMNIST、CIFAR-10 中设为 0.1，CIFAR-100 中设为 0.01。

评价指标：延续第三章的评估方式，从准确率、通信与计算效率以及收敛速度三个方面进行比较。

模型异构环境：沿用第三章的三种配置 HtFE2、HtFE4 和 HtFE5，分别对应 2 种、4 种和 5 种模型架构的组合。

超参数设置：FedPSS 中客户端对比损失权重 $\lambda = 0.1$ ，服务端放缩超参数 $\mu = 1.6 \times 10^{-4}$ ，使用基于余弦的步长衰减（上限 $\eta_{\max} = 1$ ，下限 $\eta_{\min} = 0.6$ ）。其余参数与第三章一致。

实验环境：与第三章相同。

4.4.3 基线方法

侧重于原型共享与通信效率，因此需要重点对比基于原型的方法（FedProto、FedTGP、FedLFP），同时保留部分代表性非原型方法作为性能参照。本章将 FedPSS 与 8 种异构联邦学习基线方法进行比较，这些方法涵盖了多种策略。基线方法具体包括：

- 基于模型混合的异构联邦学习方法，如 LG-FedAvg^[49]，FedSSA^[52]。
- 基于知识蒸馏的异构联邦学习方法，如 FedKDDC^[32]。
- 基于互学习的异构联邦学习方法，如 pFedAFM^[57]。
- 基于模型参数压缩方法，如 FedRAL^[59]。
- 基于原型的异构联邦学习方法，如 FedProto^[47]，FedTGP^[60]，FedLFP^[61]。

4.5 实验评估

4.5.1 准确率评估

为回答问题 1，本节实验针对图像分类任务评估了 FedPSS 算法与 8 种基线方法的性能。实验结果汇总于表4-2、表4-3、表4-4和表4-5，其中最优结果以加粗标出，次优结果以下划线标示。实验覆盖 20 与 50 两种客户端规模，并设置 HtFE2、HtFE4 和 HtFE5 三种模型异构场景，并通过调节狄利克雷浓度参数 α 来控制数据异构程度：FMNIST 与 CIFAR-10 数据集设定 $\alpha=0.1$ ，CIFAR-100 则采用更低的 $\alpha=0.01$ ，以此构建从相对简单到较为困难的渐进式异构分类环境。表中“AVG”列为各方法在三个数据集上的平均准确率，“ Δ ”则反映其相对于 LG-FedAvg 准确率的领先幅度。

表 4-2 实际数据分布下各算法准确率（HtFE2）

HtFE2	算法	FMNIST	CIFAR10	CIFAR100	AVG	Δ
20 客户端	LG-FedAvg, 20-arxiv ^[49]	95.96	84.61	72.14	84.24	/
	FedProto, 22-AAAI ^[47]	96.25	85.56	<u>73.43</u>	85.08	+0.84
	FedTGP, 24-AAAI ^[60]	96.24	85.93	73.37	85.18	+0.94
	FedSSA, 24-IJCAI ^[52]	96.23	85.54	73.31	85.03	+0.79
	FedKDDC, 25-Neural Netw ^[32]	<u>96.59</u>	<u>86.01</u>	73.24	<u>85.28</u>	<u>+1.04</u>
	FedRAL, 25-ICCV ^[59]	96.20	85.85	72.84	84.96	+0.72
	pFedAFM, 25-ICDE ^[57]	96.11	85.90	72.70	84.90	+0.66
	FedLFP, 25-TMC ^[61]	96.07	85.59	73.00	84.89	+0.65
	FedPSS (本章)	96.99	86.60	74.01	85.87	+1.63
50 客户端	LG-FedAvg, 20-arxiv ^[49]	96.81	81.59	76.33	84.91	/
	FedProto, 22-AAAI ^[47]	96.98	82.58	79.50	86.35	+1.44
	FedTGP, 24-AAAI ^[60]	96.89	<u>82.81</u>	79.76	<u>86.49</u>	<u>+1.58</u>
	FedSSA, 24-IJCAI ^[52]	<u>97.07</u>	81.77	79.50	86.11	+1.20
	FedKDDC, 25-Neural Netw ^[32]	96.78	82.43	<u>80.01</u>	86.41	+1.50
	FedRAL, 25-ICCV ^[59]	96.72	82.53	79.16	86.14	+1.23
	pFedAFM, 25-ICDE ^[57]	96.78	81.67	78.99	85.81	+0.90
	FedLFP, 25-TMC ^[61]	97.04	82.51	78.21	85.92	+1.01
	FedPSS (本章)	97.14	82.23	81.05	87.15	+2.24

HtFE2 异构配置下，结合表4-2和表4-3的实验结果可以看出，FedPSS 算法在实际数据分布和病态数据分布下均表现出较好的性能。

在实际数据分布下（表4-2），HtFE2 配置下各算法整体性能最高，任务难度相对适中。从表4-2可以看出，在 20 客户端场景中，FedPSS 取得 85.87% 的平均准确率，较 LG-FedAvg 基准提升 1.63%。与同类方法相比，FedPSS 优于 FedProto (85.08%)、FedTGP (85.18%) 和 FedLFP (84.89%) 等基于原型的方法，表明 FedPSS 在有效保护隐私的同时，能实现更优的模型性能。当客户端数量扩展至 50 时，FedPSS 的优势进一步扩大，平均准确率提升至 87.15%，相对基准的领先幅度达 2.24%。值得注意的是，在最具挑战性的 CIFAR-100 数据集上，FedPSS 取得 81.05% 的准确率，较次优方法 FedKDDC 高出 1.04%，这是因为 CIFAR-100 类别数多、类间相似度高，对特征表示的质量要求更高。说明了 FedPSS 的双层对比学习机制，在特征空间中构建了更紧凑的类内聚簇和更清晰的类间边界，充分体现了其在处理数据异构任务时的优越性。

表 4-3 病态数据分布下各算法准确率（HtFE2）

HtFE2	算法	FMNIST	CIFAR10	CIFAR100	AVG	Δ
20 客户端	LG-FedAvg, 20-arxiv ^[49]	99.32	87.91	63.86	83.70	/
	FedProto, 22-AAAI ^[47]	99.31	87.91	64.24	83.82	+0.12
	FedTGP, 24-AAAI ^[60]	<u>99.35</u>	88.18	65.04	<u>84.19</u>	<u>+0.49</u>
	FedSSA, 24-IJCAI ^[52]	99.33	87.88	63.33	83.51	-0.19
	FedKDDC, 25-Neural Netw ^[32]	99.32	87.81	64.17	83.77	+0.07
	FedRAL, 25-ICCV ^[59]	99.31	88.04	63.51	83.62	-0.08
	pFedAFM, 25-ICDE ^[57]	99.34	87.80	63.31	83.48	-0.22
	FedLFP, 25-TMC ^[61]	99.33	<u>88.36</u>	64.41	84.03	+0.33
	FedPSS (本章)	99.37	88.69	<u>65.03</u>	84.36	+0.66
50 客户端	LG-FedAvg, 20-arxiv ^[49]	99.03	84.04	53.94	79.00	/
	FedProto, 22-AAAI ^[47]	99.13	84.54	54.10	79.26	+0.26
	FedTGP, 24-AAAI ^[60]	<u>99.20</u>	84.96	54.93	79.70	+0.70
	FedSSA, 24-IJCAI ^[52]	99.13	84.24	55.30	79.56	+0.56
	FedKDDC, 25-Neural Netw ^[32]	99.16	84.58	54.21	79.32	+0.32
	FedRAL, 25-ICCV ^[59]	99.13	84.18	53.48	78.93	-0.07
	pFedAFM, 25-ICDE ^[57]	99.06	84.34	53.53	78.98	-0.02
	FedLFP, 25-TMC ^[61]	99.11	<u>85.03</u>	<u>55.15</u>	<u>79.76</u>	<u>+0.76</u>
	FedPSS (本章)	99.22	85.14	55.65	80.00	+1.00

在病态数据分布下（表4-3），FedPSS 同样表现出强鲁棒性，在 20 和 50 客户端场景下平均准确率分别为 84.36% 和 80.00%，较 LG-FedAvg 提升 0.66 和 1.00 个百分点。在

CIFAR10 上达到 88.69%，在 CIFAR100 上达到 65.03%，仅次于 FedTGP (65.04%)。尽管如此，FedPSS 在三个数据集上的平均准确率仍保持最优，验证了其在多数场景下的稳健性。在 50 个客户端的场景下，FedPSS 在所有数据集上均取得了最优结果，平均准确率为 80.00%，提升幅度达 1.00%。尤其是在 CIFAR100 上，FedPSS 达到 55.65%，比次优方法 FedTGP 高出 0.72%，进一步验证了其在极端数据异构条件下的鲁棒性和知识迁移能力。

表 4-4 实际数据分布下各算法准确率 (HtFE4)

HtFE4	算法	FMNIST	CIFAR10	CIFAR100	AVG	Δ
20 客户端	LG-FedAvg, 20-arxiv ^[49]	95.91	82.38	69.02	82.44	/
	FedProto, 22-AAAI ^[47]	96.97	82.22	70.40	83.20	+0.76
	FedTGP, 24-AAAI ^[60]	96.61	<u>83.63</u>	71.18	<u>83.81</u>	<u>+1.37</u>
	FedSSA, 24-IJCAI ^[52]	96.42	82.57	70.45	83.15	+0.71
	FedKDDC, 25-Neural Netw ^[32]	96.11	82.71	69.99	82.94	+0.50
	FedRAL, 25-ICCV ^[59]	95.39	83.62	70.39	83.14	+0.70
	pFedAFM, 25-ICDE ^[57]	96.31	82.24	70.36	82.97	+0.53
	FedLFP, 25-TMC ^[61]	95.25	82.97	<u>71.36</u>	83.19	+0.75
	FedPSS (本章)	<u>96.91</u>	85.91	72.26	85.03	+2.59
50 客户端	LG-FedAvg, 20-arxiv ^[49]	95.10	80.15	72.22	82.49	/
	FedProto, 22-AAAI ^[47]	95.66	80.68	75.95	84.10	+1.61
	FedTGP, 24-AAAI ^[60]	94.52	81.99	75.80	84.10	+1.61
	FedSSA, 24-IJCAI ^[52]	95.13	81.30	76.21	84.21	+1.72
	FedKDDC, 25-Neural Netw ^[32]	95.77	81.73	76.01	84.50	+2.01
	FedRAL, 25-ICCV ^[59]	95.54	82.24	75.79	84.52	+2.03
	pFedAFM, 25-ICDE ^[57]	<u>95.86</u>	<u>82.28</u>	75.50	84.55	+2.06
	FedLFP, 25-TMC ^[61]	95.52	81.70	<u>76.61</u>	<u>84.61</u>	<u>+2.12</u>
	FedPSS (本章)	96.17	82.33	77.95	85.48	+2.99

HtFE4 配置下模型异构程度加剧，各算法在实际分布中的平均性能普遍较 HtFE2 有所下降，但 FedPSS 仍保持稳定的性能优势。由表4-4可知，在 20 客户端场景中，在 FMNIST 中 FedPSS(96.61%) 的表现略低于 FedProto(96.97%)，但 FedPSS 平均准确率为 85.03%，较基准 (82.44%) 提升 2.59%，领先幅度较 HtFE2 进一步扩大，与次优方法 FedTGP 相比，FedPSS 高出 1.22%。在 50 客户端场景中，FedPSS 平均准确率达 85.48%，相对基准 (82.49%) 提升 2.99%，在三种异构场景中取得了最大的性能优势。值得关注的是，特别

是在 CIFAR-100 这一最具挑战性的任务上，其领先次优方法达到 1.34%，表明了步长衰减聚合策略通过动态调节聚合步长，在训练初期促进多样化知识探索，后期逐步衰减步长以增强历史知识的权重，有效抑制了因模型异构加剧带来的更新方向震荡，在数据与模型双重异构的环境中仍能保持高效的协同训练能力。

在 HtFE5 架构下（表4-5），模型异构程度达到最高。表4-5数据显示，在 20 客户端场景下，FedPSS 平均准确率为 84.45%，较 LG-FedAvg 基准（82.86%）提升 1.59%，领先 FedProto（83.26%）、FedTGP（83.75%）和 FedSSA（83.78%），领先幅度分别为 1.19、0.70 和 0.67 个百分点。在 50 客户端场景中，FedPSS 平均准确率提升为 85.46%，优于其他基线方法。从 HtFE2 到 HtFE5，随着模型异构程度递增，FedPSS 在 20 客户端场景下

表 4-5 实际数据分布下各算法准确率（HtFE5）

HtFE5	算法	FMNIST	CIFAR10	CIFAR100	AVG	Δ
20 客户端	LG-FedAvg, 20-arxiv ^[49]	96.78	82.23	69.58	82.86	/
	FedProto, 22-AAAI ^[47]	96.70	82.60	70.48	83.26	+0.40
	FedTGP, 24-AAAI ^[60]	96.89	82.88	71.47	83.75	+0.89
	FedSSA, 24-IJCAI ^[52]	96.70	82.98	<u>71.65</u>	<u>83.78</u>	<u>+0.92</u>
	FedKDDC, 25-Neural Netw ^[32]	<u>96.91</u>	83.04	70.37	83.44	+0.58
	FedRAL, 25-ICCV ^[59]	96.78	<u>83.12</u>	70.84	83.58	+0.72
	pFedAFM, 25-ICDE ^[57]	96.39	83.05	71.38	83.61	+0.75
	FedLFP, 25-TMC ^[61]	96.93	82.66	70.92	83.50	+0.64
	FedPSS (本章)	97.69	83.37	72.29	84.45	+1.59
50 客户端	LG-FedAvg, 20-arxiv ^[49]	95.38	80.13	76.04	83.85	/
	FedProto, 22-AAAI ^[47]	95.30	79.95	77.68	84.31	+ 0.46
	FedTGP, 24-AAAI ^[60]	95.39	80.36	<u>77.78</u>	84.51	+ 0.66
	FedSSA, 24-IJCAI ^[52]	95.39	<u>80.71</u>	77.44	84.51	+0.66
	FedKDDC, 25-Neural Netw ^[32]	95.47	80.19	77.45	84.37	+0.52
	FedRAL, 25-ICCV ^[59]	96.40	80.53	77.28	84.74	+0.89
	pFedAFM, 25-ICDE ^[57]	<u>96.45</u>	80.64	77.45	<u>84.85</u>	<u>+1.00</u>
	FedLFP, 25-TMC ^[61]	95.41	80.90	76.73	84.35	+0.50
	FedPSS (本章)	96.81	81.18	78.39	85.46	+1.61

的平均准确率从 85.87% 降至 84.45%，降幅为 1.42%。作为对比，FedProto、FedTGP 和 FedLFP 的准确率分别下降 1.82、1.43 和 1.39 个百分点。实验结果表明，FedPSS 平均准确率均优于对比方法，且 FedPSS 的性能衰减幅度低于多数基线方法，其原型放缩与步

长衰减聚合策略能够有效缓解模型异构带来的负面影响，在模型复杂度递增的异构环境中展现出更优的鲁棒性与稳定性。

为展示 FedPSS 在特征表示学习方面的有效性，本文以 HtFE4 模型结构下 CIFAR-10 数据集为例进行可视化分析。具体而言，测试样本经特征提取器处理后的高维特征通过 t-SNE 降维技术^[96]映射至二维空间，最终可视化结果如图4-4所示。该图对比了 FedProto、FedTGP、FedLFP 与 FedPSS 四种基于原型的方法在相同实验条件下的特征分布情况。从图中可以看出，FedProto 的特征分布虽呈现一定聚合趋势，但各类别间边界模糊、重叠较多；FedTGP 与 FedLFP 的簇结构相对更为紧凑，但类别间仍存在明显重叠；相比之下，FedPSS 的特征分布展现出最优的结构特性——各类别形成高度紧凑的簇结构，类间分离清晰且重叠较少。这一可视化结果直观验证了 FedPSS 算法的有效性。具体而言，FedPSS 通过其原型放缩与双层对比学习机制，促使同类样本在特征空间中紧密聚集，同时拉大异类样本间的距离，从而帮助分类器构建清晰稳定的决策边界，有效降低因特征重叠或模糊区域导致的分类错误。这种特征结构的优化为算法在双重异构场景下的鲁棒性与泛化性能提供了可解释的支撑。

4.5.2 通信与计算开销

为探究不同方法在资源效率方面的表现，即回答问题 2。本节以 CIFAR-10 数据集为测试基准，在客户端总数 20、迪利克雷参数 $\alpha = 0.1$ 、模型异构配置 HtFE2 的设定下，对 FedPSS 与各类基线方法的通信及计算开销进行系统评估。实验结果汇总于表4-6，涵盖测试准确率、计算耗时、内存占用及参数量传输四项指标。其中，计算时间分别以 50 轮全局训练总耗时（分钟）和单轮平均耗时（秒）两种形式呈现；内存消耗指完成 50 轮训练所需的存储空间；通信开销则从理论分析与实际测量两个维度，给出每轮通信中单个客户端需传输的参数量。符号 ϕ 代表分类头的参数量， C_i 用以描述第 i 个客户端本地数据包含的类别数目， C 代表全局数据集的类别总和， P 则代表了样本特征的维度数。此外， G_m 表示 FedRAL 的表征角矩阵。 G_θ 表示 pFedAFM 所需的小型同构模型参数量。

从表4-6的实验结果可以看出，FedPSS 在准确率为 86.60% 高于其他算法，较次优方法 FedKDDC (86.01%) 领先 0.59%，较经典方法 LG-FedAvg (84.61%) 提升 1.99%。在计算时间方面，FedPSS 总训练时间为 30.10 分钟，虽高于 LG-FedAvg (21.98 分钟)，但显著优于 pFedAFM (45.87 分钟)。内存占用上，FedPSS 与大多数基于原型方法持平，实际消耗为 1.35GB，低于 FedRAL (2.25GB) 和 pFedAFM (1.93GB)。通信成本方面，FedPSS 每轮通信量为 5.22KB，远优于 pFedAFM (6840.32KB)。然而，在相同通信水




图 4-4 不同方法特征可视化对比

平下，FedPSS 的准确率相比 FedProto、FedTGP 和 FedLFP 这些基于原型的算法均有提升，说明 FedPSS 通过步长衰减聚合策略提升全局原型收敛质量，双层对比学习增强特征判别能力，在几乎不增加通信开销的前提下提升了原型的质量与判别能力。综合而言，FedPSS 在获得最优准确率的同时，其内存占用与通信开销较低，虽然计算时间略有增加，但在整体性能与资源消耗之间取得了较好的平衡。

4.5.3 收敛曲线

图4-5展示了在 20 个客户端、HtFE4 模型异构场景下，FedPSS 及其他对比算法在 CIFAR-10 数据集上的准确率随通信轮次的变化曲线。FedPSS 在训练初期表现出最快的

表 4-6 FedPSS 及各算法计算与通信成本对比

算法	Acc. %	计算时间		内存	通信量	
		总 时间 <i>min.</i>	时间 每轮 <i>sec.</i>	(实际) 总消耗 <i>GB</i>	(理论) 每轮	(实际) 每轮 <i>KB</i>
LG-FedAvg ^[49]	84.61	21.98	26.38	1.35	$2 * \phi$	60.72
FedProto ^[47]	85.56	31.81	38.17	1.35	$(C + C_i) * P$	5.22
FedTGP ^[60]	85.93	30.95	37.14	1.35	$(C + C_i) * P$	5.22
FedSSA ^[52]	85.54	26.44	31.73	1.35	$2 * \phi$	60.72
FedKDDC ^[32]	86.01	31.82	38.18	1.35	$2 * \phi$	60.72
FedRAL ^[59]	85.85	29.55	35.46	2.25	$2 * G_m$	54.38
pFedAFM ^[57]	85.90	45.87	55.04	1.93	$2 * G_\theta$	6840.32
FedLFP ^[61]	85.59	30.08	36.09	1.35	$(C + C_i) * P$	5.22
FedPSS	86.60	30.10	36.12	1.35	$(C + C_i) * P$	5.22

上升趋势，通信轮次达到 10 轮时准确率已经领先于其他对比方法，且在第 20 轮左右开始收敛。FedPSS 全程平滑上升无明显震荡，而部分基线方法在中期出现波动。综合而言，FedPSS 在收敛速度、训练稳定性三个维度均表现最优，验证了 FedPSS 在加速模型收敛与提升异构环境下模型性能方面的有效性。




图 4-5 CIFAR10 数据集下 FedPSS 及各算法收敛曲线

4.5.4 消融实验

为深入探究 FedPSS 算法中各核心模块对整体性能的贡献程度,即回答问题 3,选取 CIFAR-10 作为数据集,20 个客户端参与训练,设定迪利克雷参数 $\alpha = 0.1$,并采用 HtFE4 模型架构。本节首先从整体层面设计消融实验,逐一移除 FedPSS 所集成的核心机制,以评估各模块对模型性能的整体贡献。在此基础上,进一步对关键模块的内部组件进行消融分析。实验结果分别汇总于表4-7和表4-8。

FedPSS 算法的核心模块主要包括了原型放缩策略、步长衰减聚合策略与客户端本地双层对比学习机制。为验证各模块的有效性,本文设计了四种消融变体:移除原型放缩策略、移除步长衰减聚合策略、移除客户端本地双层对比学习,并与完整模型进行对比。从表4-7实验结果可以看出,完整 FedPSS 模型在 CIFAR-10 数据集上取得 85.91% 的准确率。移除原型缩放策略,即使用传统的加权平均准确率为 85.54% ($\Delta = -0.37\%$),说明引入该模块在没有降低原本模型分类质量的前提下,避免了客户端直接上传样本数量信息,降低了数据分布细节被直接观测的风险,体现了该模块在降低信息暴露风险与模型性能之间的良好平衡。移除步长衰减聚合策略后,准确率下降至 82.73% ($\Delta = -3.18\%$),降幅最大,说明该策略通过动态调节聚合步长,有效抑制了异构性引入的更新方向差异,对模型收敛稳定性至关重要。移除客户端本地双层对比学习后,准确率为 83.25% ($\Delta = -2.66\%$),验证了该机制在增强特征判别能力与促进全局知识迁移方面的重要作用。同时移除三个模块后,准确率进一步降至 82.07% ($\Delta = -3.84\%$),性能损失最大,充分表明三者共同支撑 FedPSS 在双重异构场景下的优越性能。

表 4-7 FedPSS 关键模块消融实验结果

损失项	准确率 (%)	Δ 准确率 (%)
w/o 原型放缩策略	85.44	-0.47
w/o 步长衰减聚合策略	82.73	-3.18
w/o 客户端本地双层对比学习	83.25	-2.66
w/o all	82.07	-3.84
FedPSS	85.91	/

客户端双层对比学习机制包括批次内样本对比学习 L_{batch} 与全局原型对比学习 L_{global} 两个组成部分。为量化各组件对模型性能的影响,本文构建了三种消融变体:移除 L_{batch} 、移除 L_{global} 、同时移除两者 (w/o both),并与完整模型进行对比。从表4-8实

验结果可以看出, 完整 FedPSS 模型取得 85.91% 的准确率。当移除批次内样本对比学习项 L_{batch} 时, 准确率下降至 84.55% ($\Delta = -1.36\%$), 说明该机制通过拉近同类样本在特征空间的距离, 有效提升了本地特征的判别能力; 当移除全局原型对比学习项 L_{global} 时, 准确率降至 83.79% ($\Delta = -2.12\%$), 下降幅度更大, 表明全局原型对比学习在引导本地特征向全局语义空间对齐方面发挥着更为关键的作用。同时移除两项对比学习后, 准确率进一步降至 83.25% ($\Delta = -2.66\%$), 证实了两种对比学习机制在增强特征表示质量上的协同效应。

表 4-8 客户端双层对比学习消融实验结果

损失项	准确率 (%)	Δ 准确率 (%)
w/o 批次内样本对比学习 L_{batch}	84.55	-1.36
w/o 全局原型对比学习 L_{global}	83.79	-2.12
w/o both	83.25	-2.66
FedPSS	85.91	/

为直观验证 FedPSS 中双层对比学习机制对特征表示质量的提升效果, 本章还对不同损失组合下的客户端特征分布进行 t-SNE 可视化, 实验结果如图4-6所示。仅使用交叉熵损失 L_{ce} 时, 各类别特征分布分散且边界模糊; 引入批次内对比学习 L_{batch} 后, 类内样本开始聚合, 判别能力有所提升; 加入全局原型对比学习 L_{global} 后, 特征分布形成更紧凑的簇结构, 类间边界更加清晰; 而完整采用 $L_{ce} + L_{batch} + L_{global}$ 组合时, 特征分布呈现出最优的类内聚合与类间分离效果。这一结果充分验证了 FedPSS 双层对比学习机制在双重异构场景下增强特征判别能力方面的有效性。

4.5.5 超参数实验

本小节对问题 4 进行解答, 即在 FedPSS 算法下如何通过超参数配置实现模型性能的优化。选取 CIFAR-10 作为数据集, 选取 20 个客户端参与训练, 设定迪利克雷参数 $\alpha = 0.1$, 并采用 HiFE4 模型架构开展超参数调优实验。在 FedPSS 全局分类头下发过程中, 通过超参数 μ 调节全局原型大小的尺度 (公式4-5), 调节双层对比学习的加权比例 (公式4-8)。

从表4-9展示了 μ 取值从 1.2×10^{-4} 到 2.0×10^{-4} 范围内的性能表现, 当 $\mu = 1.6 \times 10^{-4}$ 时模型取得最高准确率 85.91%, 而偏离最优值会导致性能下降, $\mu = 1.2 \times 10^{-4}$ 时准确率降至 83.84% ($\Delta = -2.07\%$), $\mu = 2.0 \times 10^{-4}$ 时准确率为 84.61% ($\Delta = -1.30\%$)。




图 4-6 FedPSS 不同损失组合下的特征空间可视化对比

表 4-9 原型放缩超参数 μ 不同取值对 FedPSS 算法性能影响

μ	1.2×10^{-4}	1.4×10^{-4}	1.6×10^{-4}	1.8×10^{-4}	2.0×10^{-4}
FedPSS	83.84	85.38	85.91	84.94	84.61
Δ	-2.07	-0.53	0.00	-0.97	-1.30

表4-10则呈现了 λ 在 $\{0.05, 0.1, 0.3, 0.5\}$ 取值下的实验结果：当 $\lambda = 0.1$ 时模型取得最佳准确率 85.91%， $\lambda = 0.05$ 时准确率降至 83.74% ($\Delta = -2.17\%$)， $\lambda = 0.5$ 时准确率为 83.66% ($\Delta = -2.25\%$)。说明双层对比学习的强度需适度，过弱无法充分挖掘特征间

的判别信息，过强则会引入冗余干扰。

表 4-10 双层对比学习超参数 λ 不同取值对 FedPSS 算法性能影响

λ	0.05	0.1	0.3	0.5
FedPSS	83.74	85.91	84.63	83.66
Δ	-2.17	0.00	-1.28	-2.25

4.6 本章总结

针对当前异构联邦学习中的挑战，本章提出了一种基于原型的异构联邦学习算法 FedPSS。该算法旨在保护客户端数据隐私的同时，提升数据与模型双重异构场景下的模型性能与通信效率。FedPSS 通过引入三项核心策略解决了现有方法的不足。在原型上传方面，FedPSS 通过原型放缩策略，将样本数量信息隐式编码于放缩后的原型中，在不牺牲聚合精度的前提下，实现了从显式上传到隐式传输的转变，降低了数据分布被直接观测的风险。在服务端聚合中采用，步长衰减聚合策略动态调节聚合权重，吸收历史知识并加速收敛。双层对比学习策略提升本地样本表征质量，利用批次内损失 L_{batch} 强化局部判别边界，并借助全局损失 L_{global} 引导模型向全局共性空间对齐。为全面验证 FedPSS 的有效性，本章选取了 8 个代表性联邦学习基线模型，在多种异构程度以及不同数据集上进行系统对比。实验结果表明，FedPSS 在模型准确率方面具有优势，有效加速了收敛速度，降低了通信开销并从通信内容层面减少了数据分布细节的直接暴露，更适合资源受限且对隐私保护有严格要求的场景。

5 总结与展望

5.1 工作总结

联邦学习作为一种隐私保护的分布式机器学习方法，通过本地数据保留与模型参数交换的机制实现多方协同训练。然而，在联邦学习实际应用中，客户端普遍存在双重异构性：数据异构，客户端本地数据分布不满足独立同分布，导致模型更新方向偏离全局最优；模型异构，受设备资源与隐私限制，客户端难以统一模型架构。数据和模型的双重异构性已成为制约联邦学习性能与实用性的核心瓶颈，这使得面向异构场景的联邦学习成为重要的研究方向。本文系统回顾了面向数据异构与模型异构的联邦学习相关工作。针对客户端数据异构、模型结构异构以及通信开销等问题，分别提出了两种异构联邦学习方法：

(1) 针对异构联邦学习中数据分布差异与模型结构异构的双重挑战，本文提出了一种名为 FedIADA 的个性化联邦学习算法。该算法通过三项核心策略协同优化异构环境下的分类性能与泛化能力。服务器端创新提出类内聚合机制，融合样本数量与分类质量权重生成高质量类内聚合表示，并与客户端间聚合结果结合，构建判别能力更强的全局分类头。在客户端侧，FedIADA 引入了一种自适应融合策略，利用可训练的权重矩阵动态平衡全局知识与本地个性化知识。除此之外，引入了自适应 logits 调整机制，基于本地数据分布对输出 logits 进行平滑校准，有效提升了模型对少数类别的识别能力与预测公平性。实验结果表明，FedIADA 在多种数据与模型异构场景下均取得了优越的性能，显著提升了分类准确率。该算法不仅充分利用了类别间的结构化信息，还通过细粒度的自适应机制实现了全局知识迁移与本地个性化保留之间的有效平衡，为异构联邦学习场景下的模型训练提供了一种高效且鲁棒的解决方案。

(2) 针对异构联邦学习中服务端聚合存在的暴露类别数量信息与通信量过大的问题，本文提出基于原型放缩与步长衰减的联邦学习算法 FedPSS。FedPSS 设计了原型放缩策略：客户端依据本地样本数量放大原型后上传，服务器聚合生成全局原型后再缩小下发，使客户端无需上传原始样本数量即可完成原型聚合，降低了聚合过程中的信息泄漏风险。在聚合策略方面，引入步长衰减机制动态调节聚合步长，训练初期以较大步长吸收多样化知识，后期逐步减小步长抑制更新方向差异与震荡，提升收敛稳定性与最终性能。此外，双层对比学习策略使客户端在学习全局原型知识的同时提高本地样本表征质

量, 进一步提升模型泛化能力。实验结果表明, 在保证模型准确率基本不下降的前提下, FedPSS 显著降低通信开销并避免了样本数量信息的直接传输, 有效缓解现有原型聚合方法的不足。相比于 FedIADA 更适合大规模、资源受限的边缘计算场景, 尤其是对通信效率和隐私保护有双重严苛要求的应用。

5.2 未来展望

本研究主要围绕数据与模型双重异构这一核心挑战进行算法的设计与改良, 未来的工作可从以下几个维度进行深化探索与拓展。

(1) FedIADA 算法主要解决的是特征提取器部分异构的情况。后续工作可以考虑将 FedIADA 推广至更为模型完全异构场景。

(2) FedPSS 利用原型放缩来保护隐私, 后续研究可考虑将其与差分隐私、安全多方计算等隐私技术, 在更好保护隐私的同时, 提高模型性能。

(3) 目前的 FedPSS 算法的个性化能力不足, 可以通过聚类联邦学习或者蒸馏等方法进一步提升模型的个性化能力。

(4) 未来可以把两个方法优势之处相互结合。

参考文献

- [1] Uddin M P, Xiang Y, Hasan M, et al. A systematic literature review of robust federated learning: Issues, solutions, and future research directions[J]. ACM Computing Surveys, 2025, 57(10): 1 - 62.
- [2] Johnson F T, Oladapo E, Olugbenga O, et al. Communication-Efficient Federated Learning: A Systematic Review of Model Compression and Aggregation Techniques[C] // Artificial Intelligence and Applications. 2025.
- [3] Voigt P, Von dem Bussche A. The eu general data protection regulation (gdpr)[J]. A Practical Guide, 1st ed., Cham: Springer International Publishing, 2017, 10(3152676): 10 - 5555.
- [4] Harding E L, Vanto J J, Clark R, et al. Understanding the scope and impact of the california consumer privacy act of 2018[J]. Journal of Data Protection & Privacy, 2019, 2(3): 234 - 253.
- [5] Shahrullah R S, Park J, Irwansyah I. Examining personal data protection law of Indonesia and South Korea: The privacy rights fulfilment[J]. Hasanuddin Law Review, 2025, 10(1): 1 - 20.
- [6] McMahan B, Moore E, Ramage D, et al. Communication-efficient learning of deep networks from decentralized data[C] // Artificial Intelligence and Statistics. 2017: 1273 - 1282.
- [7] Hernandez-Cruz N, Saha P, Sarker M M K, et al. Review of federated learning and machine learning-based methods for medical image analysis[J]. Big Data and Cognitive Computing, 2024, 8(9): 99.
- [8] Dhanawat V, Shinde V, Karande V, et al. Enhancing financial risk management with federated AI[C] // 2024 8th SLAAI International Conference on Artificial Intelligence. 2024: 1 - 6.
- [9] Chen L, Zhao D, Tao L, et al. A credible and fair federated learning framework based on blockchain[J]. IEEE Transactions on Artificial Intelligence, 2024, 6(2): 301 - 316.

-
- [10] Berkani M R A, Chouchane A, Himeur Y, et al. Advances in federated learning: Applications and challenges in smart building environments and beyond[J]. Computers, 2025, 14(4): 124.
- [11] Chen C, Liao T, Deng X, et al. Advances in robust federated learning: A survey with heterogeneity considerations[J]. IEEE Transactions on Big Data, 2025, 11(3): 1548 - 1567.
- [12] Saeed N, Ashour M, Mashaly M. Comprehensive review of federated learning challenges: A data preparation viewpoint[J]. Journal of Big Data, 2025, 12(1): 153.
- [13] Zhao Y, Li M, Lai L, et al. Federated learning with non-iid data[J]. arXiv preprint arXiv:1806.00582, 2018.
- [14] Lu Z, Pan H, Dai Y, et al. Federated learning with non-iid data: A survey[J]. IEEE Internet of Things Journal, 2024, 11(11): 19188 - 19209.
- [15] Li D, Wang J. Fedmd: Heterogenous federated learning via model distillation[J]. arXiv preprint arXiv:1910.03581, 2019.
- [16] Yi L, Yu H, Ren C, et al. pfedes: Generalized proxy feature extractor sharing for model heterogeneous personalized federated learning[C] // Proceedings of the AAAI Conference on Artificial Intelligence : 39. 2025 : 22146 - 22154.
- [17] Zhao Z, Mao Y, Shi Z, et al. Aquila: Communication efficient federated learning with adaptive quantization in device selection strategy[J]. IEEE Transactions on Mobile Computing, 2023, 23(6): 7363 - 7376.
- [18] Karimireddy S P, Kale S, Mohri M, et al. Scaffold: Stochastic controlled averaging for federated learning[C] // International Conference on Machine Learning. 2020 : 5132 - 5143.
- [19] 何帆, 王勇, 杨静, 等. 面向边缘计算场景的个性化联邦学习综述 [J]. 通信学报, 2025, 46(7).
- [20] Chen H, Frikha A, Krompass D, et al. Fraug: Tackling federated learning with non-iid features via representation augmentation[C] // Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023 : 4849 - 4859.
- [21] Lewy D, Mańdziuk J, Ganzha M, et al. StatMix: Data augmentation method that relies on image statistics in federated learning[C] // International Conference on Neural Information Processing. 2022 : 574 - 585.

- [22] Xin B, Yang W, Geng Y, et al. Private fl-gan: Differential privacy synthetic data generation based on federated learning[C] // Icassp 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing. 2020 : 2927 - 2931.
- [23] Zhang J, Jiang Y. A data augmentation method for vertical federated learning[J]. Wireless Communications and Mobile Computing, 2022, 2022(1) : 6596925.
- [24] Chen L, Ang F, Chen Y, et al. Robust federated learning with noisy labeled data through loss function correction[J]. IEEE Transactions on Network Science and Engineering, 2022, 10(3) : 1501 - 1511.
- [25] Duan S, Liu C, Cao Z, et al. Fed-DR-Filter: Using global data representation to reduce the impact of noisy labels on the performance of federated learning[J]. Future Generation Computer Systems, 2022, 137 : 336 - 348.
- [26] Arivazhagan M G, Aggarwal V, Singh A K, et al. Federated learning with personalization layers[J]. arXiv preprint arXiv:1912.00818, 2019.
- [27] Collins L, Hassani H, Mokhtari A, et al. Exploiting shared representations for personalized federated learning[C] // International Conference on Machine Learning. 2021 : 2089 - 2099.
- [28] Shen Y, Zhou Y, Yu L. Cd2-pfed: Cyclic distillation-guided channel decoupling for model personalization in federated learning[C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022 : 10041 - 10050.
- [29] 孙艳华, 史亚会, 王朱伟, 等. 基于元蒸馏的个性化联邦学习算法 [J]. 北京邮电大学学报, 2023, 46(1) : 12.
- [30] Zhu Z, Hong J, Zhou J. Data-free knowledge distillation for heterogeneous federated learning[C] // International Conference on Machine Learning. 2021 : 12878 - 12889.
- [31] Jeong E, Oh S, Kim H, et al. Communication-efficient on-device machine learning: Federated distillation and augmentation under non-iid private data[J]. arXiv preprint arXiv:1811.11479v2, 2018.
- [32] Zhang Z, Mu C, Guo K, et al. Knowledge-distillation based personalized federated learning with distribution constraints[J]. Neural Networks, 2025 : 107951.
- [33] Li T, Sahu A K, Zaheer M, et al. Federated optimization in heterogeneous networks[J]. Proceedings of Machine Learning and Systems, 2020, 2 : 429 - 450.

- [34] Shoham N, Avidor T, Keren A, et al. Overcoming forgetting in federated learning on non-iid data[J]. arXiv preprint arXiv:1910.07796, 2019.
- [35] Yao X, Sun L. Continual local training for better initialization of federated models[C] // 2020 IEEE International Conference on Image Processing. 2020 : 1736 - 1740.
- [36] T Dinh C, Tran N, Nguyen J. Personalized federated learning with moreau envelopes[J]. Advances in Neural Information Processing Systems, 2020, 33 : 21394 - 21405.
- [37] Li T, Hu S, Beirami A, et al. Ditto: Fair and robust federated learning through personalization[C] // International Conference on Machine Learning. 2021 : 6357 - 6368.
- [38] Lu X, Li P, Jiang X. FedLF: Adaptive Logit Adjustment and Feature Optimization in Federated Long-Tailed Learning[C] // Proceedings of the 16th Asian Conference on Machine Learning. 2025 : 303 - 318.
- [39] Smith V, Chiang C-K, Sanjabi M, et al. Federated multi-task learning[J]. Advances in Neural Information Processing Systems, 2017, 30.
- [40] Scott J, Zakerinia H, Lampert C H. PeFLL: Personalized federated learning by learning to learn[J]. arXiv preprint arXiv:2306.05515, 2023.
- [41] Zhang J, Hua Y, Wang H, et al. Fedala: Adaptive local aggregation for personalized federated learning[C] // Proceedings of the AAAI Conference on Artificial Intelligence : 37. 2023 : 11237 - 11244.
- [42] Yang X, Huang W, Ye M. Fedas: Bridging inconsistency in personalized federated learning[C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024 : 11986 - 11995.
- [43] Ye M, Fang X, Du B, et al. Heterogeneous federated learning: State-of-the-art and research challenges[J]. ACM Computing Surveys, 2023, 56(3) : 1 - 44.
- [44] 汤尧, 刘健. 异构数据环境下的联邦学习综述 [J]. 网络空间安全科学学报, 2025, 3(2) : 2 - 11.
- [45] Yi L, Yu H, Ren C, et al. Federated model heterogeneous matryoshka representation learning[J]. Advances in Neural Information Processing Systems, 2024, 37 : 66431 - 66454.
- [46] Diao E, Ding J, Tarokh V. HeteroFL: Computation and Communication Efficient Federated Learning for Heterogeneous Clients[C] // International Conference on Learning Representations. 2021.

- [47] Tan Y, Long G, Liu L, et al. Fedproto: Federated prototype learning across heterogeneous clients[C] // Proceedings of the AAAI Conference on Artificial Intelligence : 36. 2022 : 8432 - 8440.
- [48] Pfeiffer K, Rapp M, Khalili R, et al. Federated learning for computationally constrained heterogeneous devices: A survey[J]. ACM Computing Surveys, 2023, 55(14s) : 1 - 27.
- [49] Liang P P, Liu T, Ziyin L, et al. Think locally, act globally: Federated learning with local and global representations[J]. arXiv preprint arXiv:2001.01523, 2020.
- [50] Yi L, Wang G, Liu X, et al. Fedgh: Heterogeneous federated learning with generalized global header[C] // Proceedings of the 31st ACM International Conference on Multimedia. 2023 : 8686 - 8696.
- [51] Wang J, Yang X, Cui S, et al. Towards personalized federated learning via heterogeneous model reassembly[J]. Advances in Neural Information Processing Systems, 2023, 36 : 29515 - 29531.
- [52] Yi L, Yu H, Shi Z, et al. FedSSA: Semantic similarity-based aggregation for efficient model-heterogeneous personalized federated learning[C] // Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence. 2024.
- [53] Chang H, Shejwalkar V, Shokri R, et al. Cronus: Robust and heterogeneous collaborative learning with black-box knowledge transfer[J]. arXiv preprint arXiv:1912.11279, 2019.
- [54] Shen T, Zhang J, Jia X, et al. Federated mutual learning[J]. arXiv preprint arXiv:2006.16765, 2020.
- [55] Wu C, Wu F, Lyu L, et al. Communication-efficient federated learning via knowledge distillation[J]. Nature Communications, 2022, 13(1) : 2032.
- [56] Qin Z, Deng S, Zhao M, et al. FedAPEN: Personalized cross-silo federated learning with adaptability to statistical heterogeneity[C] // Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 2023 : 1954 - 1964.
- [57] Yi L, Yu H, Wang G, et al. pFedAFM: Adaptive Feature Mixture for Data-Level Personalization in Heterogeneous Federated Learning on Mobile Edge Devices[C] // 2025 IEEE 41st International Conference on Data Engineering. 2025 : 1981 - 1994.
- [58] Chen Y, Vikalo H, Wang C. Fed-QSSL: A framework for personalized federated learning under bitwidth and data heterogeneity[C] // Proceedings of the AAAI Conference on Artificial Intelligence : 38. 2024 : 11443 - 11452.

- [59] Yi L, Yu H, Wang G, et al. Federated Representation Angle Learning[C] // Proceedings of the IEEE/CVF International Conference on Computer Vision. 2025 : 1314 - 1324.
- [60] Zhang J, Liu Y, Hua Y, et al. Fedtgp: Trainable global prototypes with adaptive-margin-enhanced contrastive learning for data and model heterogeneity in federated learning[C] // Proceedings of the AAAI Conference on Artificial Intelligence : 38. 2024 : 16768 - 16776.
- [61] Sun Y, Pan S, Sun A, et al. Fedlfp: Communication-efficient personalized federated learning on non-iid data in mobile edge computing environments[J]. IEEE Transactions on Mobile Computing, 2025.
- [62] Lee G, Shin J, Choi D. Heterogeneous Federated Learning with Prototype Alignment and Upscaling[J]. arXiv preprint arXiv:2507.04310, 2025.
- [63] Fang J, Ke J, Chen J, et al. FedHCL: Hierarchical Cluster Fine-Grained Prototype Contrastive Learning for Multi-Feature Distributions and Model Heterogeneity in FL[J]. IEEE Internet of Things Journal, 2025.
- [64] 杨智凯, 刘亚萍, 张硕, 等. 联邦学习通信优化方法综述 [J]. 网络与信息安全学报, 2024, 10(6) : 1 - 23.
- [65] Jia N, Qu Z, Ye B, et al. A comprehensive survey on communication-efficient federated learning in mobile edge environments[J]. IEEE Communications Surveys & Tutorials, 2025, 27(6) : 3710 - 3741.
- [66] Bernstein J, Wang Y-X, Azizzadenesheli K, et al. signSGD: Compressed optimisation for non-convex problems[C] // International Conference on Machine Learning. 2018 : 560 - 569.
- [67] Sattler F, Wiedemann S, Müller K-R, et al. Robust and communication-efficient federated learning from non-iid data[J]. IEEE transactions on Neural Networks and Learning Systems, 2019, 31(9) : 3400 - 3413.
- [68] Nariman G S, Hamarashid H K. Enhancing Communication Efficiency in Federated Learning Through Client Contribution Selection Based Normalized L2 Norm with Cosine Similarity and L2 Norm Filtering[J]. Journal of Studies in Science and Engineering, 2025, 5(1) : 1 - 23.

- [69] DN S, B A, Ambesange S. Smart client selection strategies for enhanced federated learning in digital healthcare applications[J]. *Multimedia Tools and Applications*, 2025, 84(19): 21589 - 21604.
- [70] Yan K, Wu T, Shu N, et al. FedCCS: Efficient Federated Learning with Clustering-Based Client Selection and Bandwidth Allocation[C] // 2025 IEEE Wireless Communications and Networking Conference. 2025: 1 - 6.
- [71] Alanazi T, Fahim A, Ibnath M, et al. FedBand: Adaptive Federated Learning Under Strict Bandwidth Constraints[C] // 2025 34th International Conference on Computer Communications and Networks. 2025: 1 - 9.
- [72] Yang Q, Liu Y, Chen T, et al. Federated machine learning: Concept and applications[J]. *ACM Transactions on Intelligent Systems and Technology*, 2019, 10(2): 1 - 19.
- [73] Li Q, Wen Z, Wu Z, et al. A survey on federated learning systems: Vision, hype and reality for data privacy and protection[J]. *IEEE Transactions on Knowledge and Data Engineering*, 2021, 35(4): 3347 - 3366.
- [74] Li Y, Guo Z, Yang N, et al. Threats and defenses in the federated learning life cycle: A comprehensive survey and challenges[J]. *IEEE Transactions on Neural Networks and Learning Systems*, 2025.
- [75] Bonawitz K, Eichner H, Grieskamp W, et al. Towards federated learning at scale: System design[J]. *Proceedings of Machine Learning and Systems*, 2019, 1: 374 - 388.
- [76] Zhou Z, Luo G, Chen M, et al. Federated learning for medical image classification: a comprehensive benchmark[J]. *IEEE Journal of Biomedical and Health Informatics*, 2025.
- [77] Manwani P, Gupta A, Misra S, et al. Federated learning for cross-bank fraud defense[J]. *International Journal of Computer Engineering and Technology*, 2025, 16(2): 221 - 241.
- [78] Alterkawi L, Dib F K. Federated Learning for Smart Cities: A Thematic Review of Challenges and Approaches[J]. *Future Internet*, 2025, 17(12): 545.
- [79] Kairouz P, McMahan H B. Advances and open problems in federated learning[J]. *Foundations and Trends in Machine Learning*, 2021, 14(1-2): 1 - 210.
- [80] Tan A Z, Yu H, Cui L, et al. Towards personalized federated learning[J]. *IEEE Transactions on Neural Networks and Learning Systems*, 2022, 34(12): 9587 - 9603.

- [81] Nguyen H, Warriier H, Gupta Y. A novel approach for federated learning with non-IID data[C] // 2022 9th International Conference on Soft Computing & Machine Intelligence. 2022 : 62 - 67.
- [82] Mahdi O A, Pardede E, Bevinakoppa S, et al. Federated Learning Under Concept Drift: A Systematic Survey of Foundations, Innovations, and Future Research Directions[J]. Electronics, 2025, 14(22) : 4480.
- [83] Yan Y, Feng C-M, Ye M, et al. Addressing client drift in federated learning via class-prototype similarity distillation and adaptive mask[J]. IEEE Transactions on Cybernetics, 2025.
- [84] Alam S, Liu L, Yan M, et al. Fedrolex: Model-heterogeneous federated learning with rolling sub-model extraction[J]. Advances in Neural Information Processing Systems, 2022, 35 : 29677 - 29690.
- [85] Zhang J, Liu Y, Hua Y, et al. An upload-efficient scheme for transferring knowledge from a server-side pre-trained generator to clients in heterogeneous federated learning[C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024 : 12109 - 12119.
- [86] Zhang J, Wu X, Zhou Y, et al. Htflib: A comprehensive heterogeneous federated learning library and benchmark[C] // Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining V. 2. 2025 : 5900 - 5911.
- [87] Xiao H, Rasul K, Vollgraf R. Fashion-mnist: a novel image dataset for benchmarking machine learning algorithms[J]. arXiv preprint arXiv:1708.07747, 2017.
- [88] Krizhevsky A, Hinton G, others. Learning multiple layers of features from tiny images[J], 2009.
- [89] Hsu T-M H, Qi H, Brown M. Measuring the effects of non-identical data distribution for federated visual classification[J]. arXiv preprint arXiv:1909.06335, 2019.
- [90] Yurochkin M, Agarwal M, Ghosh S, et al. Bayesian nonparametric federated learning of neural networks[C] // International Conference on Machine Learning. 2019 : 7252 - 7261.
- [91] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C] // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2015 : 1 - 9.

- [92] Sandler M, Howard A, Zhu M, et al. Mobilenetv2: Inverted residuals and linear bottle-necks[C] // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018 : 4510 - 4520.
- [93] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C] // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016 : 770 - 778.
- [94] 潘思怡. 数据和模型异构场景下的联邦学习算法研究 [D]. [S.l.]: 暨南大学, 2025.
- [95] Arazzi M, Cihangiroglu M, Nocera A. Privacy Preserving and Robust Aggregation for Cross-Silo Federated Learning in Non-IID Settings[J]. arXiv preprint arXiv:2503.04451, 2025.
- [96] Van der Maaten L, Hinton G. Visualizing data using t-SNE.[J]. Journal of Machine Learning Research, 2008, 9(11).

在学期间发表论文的清单

- (1) 第三作者. UAP4MA: Leveraging Multi-Agent Bandits to Generate Universal Adversarial Perturbations for Malware Attribution[J/OL]. IEEE Transactions on Dependable and Secure Computing, 2026. <https://dx.doi.org/10.1109/TDSC.2026.3689685>. (CCF-A 类期刊)

致 谢

本论文的顺利完成，离不开各位老师、同学和家人的关心与帮助，在此谨致以最诚挚的谢意。

首先，非常感谢梁倬骞和孙玉霞老师，在入学的时候就让我定期进行汇报科研进展，让我养成了持续学习的习惯，同时也能看到一路走来的成长轨迹。每一次汇报，你们都耐心倾听我的思路，细致地点评实验设计与阶段性成果，让我逐渐学会用更严谨更系统的眼光看待问题。这种长期稳定的互动，不仅帮助我在科研道路上稳步前行，更让我在一次次反馈中建立起自信。在这三年的时间里，经过你们的悉心教导，我的科研能力不断变强。从论文的选题，到最后的论文定稿，每个环节都凝聚着导师的心血。你们严谨负责的态度以及精益求精的科研精神，深深感染着我，是我一路前行的榜样。

感谢课题组的师兄师姐师弟师妹们，刚进组的时候，很多东西都不熟悉，感谢你们在我遇到困难时给予的技术支持和帮助。我们一起探讨问题、调试代码、交流心得的日日夜夜，你们给予我的支持、鼓励与启发，是这段旅程中最珍贵的财富。你们给我的不仅是技术上的支持，更是一次次把我从挫败感里拉出来的鼓励和提醒。这份一起并肩作战的情谊，是我这几年科研路上最实在的收获。

感谢我的室友与好友们，很多看似平常的聊天和相处，其实悄悄撑住了我很多难熬的时刻，你们的陪伴与关怀，为我平淡的科研生活增添了无数温暖与亮色。

深深感谢我的父母与家人。二十余载，你们始终是最坚实的后盾，用无私的爱与无条件的支持，赋予我直面困难、追求理想的勇气与力量。你们的理解与信任，是我不断前行的最大动力。

最后，向参与本论文评阅与答辩的各位专家、老师致以由衷的感谢。感谢你们在百忙之中抽出时间审阅这篇论文，细致地检查其中的方法与论证，并提出宝贵的修改意见。你们的每一条建议，既是对本研究工作的严谨把关，也是对我学术成长的悉心指点。

求学之路暂告段落，人生新篇即将开启。感谢所有相遇，唯愿初心不改，未来可期。